

Campañas de Marketing Bancario

Análisis mediante Técnicas de Ciencia de Datos

Maria Elena Irribarra Aguilera

Enero 2026

Universidad San Sebastián

Magíster en Data Science

Taller de Aplicaciones

Contexto del Problema

Desafío del Marketing Bancario:

- Baja tasa de conversión: **12%**
- Altos costos operativos
- Saturación de clientes
- Desperdicio de recursos

Dataset: Bank Marketing UCI

- 45,211 contactos telefónicos
- 17 variables (demográficas, financieras, campaña)
- Banco portugués (2008-2013)




Figure 1: Desbalance de clases: 88% 'no' vs 12% 'yes'

Objetivos e Hipótesis

Objetivo Principal: Optimizar campañas de telemarketing mediante ciencia de datos

Hipótesis de Trabajo:

H1 Duración de llamada es predictor fuerte de interés

H2 Historial exitoso aumenta probabilidad actual

H3 Demografía (edad, trabajo) influye en propensión

H4 Mes de contacto tiene impacto estacional

H5 Segmentación por balance revela grupos diferenciados

Metodología

CRISP-DM: EDA → Clustering → Clasificación → Apriori → Evaluación

Análisis Exploratorio: Hallazgos Clave




Figure 2: Mayo: alto volumen, conversión relativa baja




Figure 3: Correlaciones: ausencia de multicolinealidad

Decisiones Metodológicas

Desbalance 88%-12% → SMOTE

StandardScaler

— Escalas diferentes →

Segmentación: Comparación de Métodos




Figure 4: Método del Codo: $k=3$ óptimo

Método	Silhouette	Ruido
K-Means	0.0973	0%
DBSCAN	N/A	16.3%
Jerárquico	0.0473	0%

Table 1: K-Means: mejor cohesión

Decisión
K-Means ($k=3$) seleccionado por mayor Silhouette Score

Tres Perfiles de Clientes Identificados




Figure 5: Segmentación Edad-Balance

Característica	Cluster 0	Cluster 1	Cluster 2
Perfil	Senior Ahorrador	Joven Trabajador	Edad Media / Bajo Capital
Edad	57 años	35 años	38 años
Balance	\$2,932	\$1,607	\$888
Tamaño	20%	45%	35%
Estrategia	Inversión	Digital	Micro-ahorro

Clasificación: Optimización con SMOTE + Threshold




Figure 6: Umbral óptimo: 0.42

Config	Recall	F1	AUC
RF Base	47.2%	0.583	0.907
+ SMOTE (0.5)	69.8%	0.658	-
+ Threshold (0.45)	77.1%	0.675	-

Table 2: Mejora Recall: +29.9 pp, F1: +0.092

Impacto

Captura **77%** de clientes potenciales (vs 47% original)

Variables Más Influyentes




Figure 7: Top 10 Features (Random Forest)

Hallazgos Clave:

1. **Duration (35%):**
Predictor dominante.
Llamadas >3 min
aumentan éxito
exponencialmente
2. **Balance:** Perfil financiero
es crítico
3. **Age:** Demografía valida
H3
4. **Poutcome_success:**
Historial confirma H2

Validación

H1, H2, H3, H5 confirmadas

Apriori: Perfil de Alto Potencial Identificado




Figure 8: Reglas accionables (y=yes) destacadas en rojo

Perfil Estrella:

- Blue-collar + Casado
- Edad: 30-50 años (Adult)
- Educación: Primaria
- Mes: Mayo

Impacto de Negocio:

- Tamaño: 2% base (~900 clientes)
- Tasa conversión: **57.8%**
- **Lift = 4.68x** vs promedio
- ROI: +380% si se prioriza

Top 6 Reglas de Asociación

#	Antecedente	Consecuente	Conf.	Lift
1	{ primary, may, Adult }	{ blue-collar, yes, married }	57.8%	4.68
2	{ no, primary, may, Adult }	{ blue-collar, yes, married }	57.8%	4.67
3	{ primary, may, Adult }	{ blue-collar, yes, no, married }	57.3%	4.67
4	{ may, married, blue-collar }	{ yes, primary, Adult }	30.8%	4.61
5	{ may, married, blue-collar }	{ yes, no, primary, Adult }	30.5%	4.60
6	{ may, no, married, blue-collar }	{ yes, primary, Adult }	30.7%	4.60

Table 3: 22.614 reglas totales con y=yes

Interpretación del Lift

Lift = 4,68: La suscripción es **4,68 veces más probable** cuando el cliente cumple el perfil identificado

$$\text{Lift}(A \rightarrow B) = \frac{P(B|A)}{P(B)} = \frac{\text{Confidence}(A \rightarrow B)}{P(B)}$$

Conclusiones y Recomendaciones

Hallazgos Principales:

1. **3 Perfiles** diferenciados requieren estrategias personalizadas
2. **Modelo RF** robusto: AUC=0.91, Recall=77%
3. **Duración (35%)** es el predictor crítico
4. **Perfil alto potencial** identificado: 57.8% conversión
5. Reducción **57% costo de oportunidad**

Recomendaciones:

- **Corto plazo:** Scoring CRM, entrenar agentes en duración >3 min
- **Mediano plazo:** Scripts personalizados por segmento, A/B testing
- **Largo plazo:** XGBoost, feature engineering, MLOps

Impacto Proyectado

Conversión: 12% → **17%** (+42%)
ROI: 1.8x → **3.2x** (+78%)

Validación de Hipótesis

#	Hipótesis	Evidencia	Estado
H1	Duración predictor fuerte	Feature Importance = 35% (1° lugar)	OK
H2	Historial aumenta probabilidad	poutcome.success en Top 10	OK
H3	Demografía influye	Edad = 3° variable, clústeres por edad	OK
H4	Estacionalidad (mes)	Mayo: alto volumen, conversión < promedio	Parcial
H5	Segmentación por balance	Balance = 2° variable, clústeres diferenciados	OK

Resultado

4 de 5 hipótesis confirmadas con evidencia cuantitativa

Muchas gracias por su atención.