

Campañas de Telemarketing Bancario

Machine Learning Aplicado

Maria Elena Irribarra Aguilera

Concepción, 18 de enero de 2026

Universidad San Sebastián

Magíster en Data Science

Taller de Aplicaciones

Contexto y Problema de Negocio


Sector: Banca Minorista Portuguesa
(2008-2013)

Problema:

- Tasa conversión: **12%** (88% rechazo)
- Costos altos de telemarketing
- Saturación de clientes

Objetivo: Predecir suscripción a depósitos a plazo

Dataset: Moro et al. (2014). UCI ML Repository




3 Insights Clave de Negocio (CRISP-DM)

1. Variables críticas: duración llamada, resultado previo, mes contacto
2. Balance óptimo: priorizar Recall minimiza oportunidades perdidas
3. Segmentación natural: 3 clusters con respuesta diferenciada

Dataset UCI Bank Marketing: 45,211 registros, 20 variables

Moro et al. (2014). *Decision Support Systems*, 62, 22-31



Hallazgos EDA:

- Desbalance 88%-12%
- Duration sesgada derecha
- Balance bimodal (cero + normal)
- Correlación débil entre variables

3 Hallazgos de Calidad (CRISP-DM)

1. Dataset limpio: 0 nulos, 45,211 registros válidos
2. Escalado necesario: StandardScaler para edad, balance, duration
3. Categóricas clave: job, education, contact (One-Hot Encoding)

Pipeline de Preprocesamiento:

1. **OneHotEncoding:** 16 categóricas $\rightarrow$ 65 binarias
2. **StandardScaler:** Normalización de 7 numéricas
3. **SMOTE:** Balanceo 31,647 $\rightarrow$ 55,912 train samples
4. **Discretización:** age_group, balance_group, duration_group

SMOTE: Chawla et al. (2002). JAIR, 16, 321-357


Técnica	Pre	Post
Clases Train	87%-13%	50%-50%
Features	17 originales	72 procesadas

Validación de Transformaciones (CRISP-DM)

1. SMOTE mejora generalización: balanceo 1:1 aumenta Recall 65% $\rightarrow$ 90%
2. Discretización aplicada: bins=5 para variables continuas (método Sturges)
3. Feature engineering efectivo: variables procesadas para algoritmos

Segmentación de Clientes (Clustering)

Método Seleccionado: K-Means ($k=3$) — Silhouette = 0.097



3 Perfiles:

C0: Senior Ahorrador

57 años, \$2,932

C1: Joven Trabajador

35 años, \$1,607

C2: Bajo Capital

38 años, \$888

Decisiones Algorítmicas (CRISP-DM)

1. $k=3$ óptimo: método codo + Silhouette=0.097, mejora $<5\%$ en $k=4$
2. Diferenciación validada: tasas respuesta 15%, 8%, 3% por cluster
3. K-Means supera DBSCAN (ruido) y Jerárquico (costo computacional)

Método	Silhouette	Interpretab.	Ref.
Nuestro K-Means	0.097	★★★★★	-
Yan et al. KM-DBSCAN	0.92	★★★	2025

Trade-off Técnico vs. Operativo:


- Yan: Silhouette 0.92 (superior técnicamente), pero más complejo
- Nosotros: Simplicidad + Centroides explícitos e interpretables
- Ambos enfoques válidos según prioridades organizacionales

Yan et al. (2025). *Applied Sciences*, 15(6), 3138

Reflexión Crítica (CRISP-DM): Yan (2025)

1. Silhouette 0.097 (nuestro) vs. 0.92 (Yan): métricas técnicas $\neq$ valor negocio
2. KM-DBSCAN: mayor complejidad computacional (trade-off)
3. Interpretabilidad prioritaria: K-Means permite explicación a stakeholders

Clasificación: Comparativa de Modelos



Modelo	AUC	F1	Recall
LR	0.89	0.54	0.61
DT	0.82	0.48	0.52
RF	0.90	0.58	0.65


Ganador: Random Forest

AUC = 0.90 (mejor ranking)

Justificación de Métricas (CRISP-DM)

1. AUC=0.90 prioritario: datasets desbalanceados requieren métrica robusta
2. Trade-off definido: Recall 90% (capturar clientes) vs. Precision 58%
3. Modelo optimizado para maximizar captura de oportunidades de negocio

Mejora: SMOTE + Threshold Tuning



Safarkhani & Moro (2021). *Applied Sciences*, 11(19), 9016

Mejora Alcanzada:

Config	Recall	F1
RF Base	65%	0.58
+ SMOTE + T	90%	0.68


Umbral Óptimo: 0.42 (vs. 0.50)

+25pp Recall = Capturar 9 de 10 clientes

Análisis Comparativo (CRISP-DM): Akkaya (2024)

1. Recall prioritario: costo oportunidad perdida supera costo llamada innecesaria
2. Validación umbral 0.42: 10-fold CV confirma estabilidad
3. Impacto: 90% Recall captura +25 puntos porcentuales de clientes potenciales

Importancia de Variables (Feature Importance)



Top 3 Variables:

1. **Duration (35%)**

Advertencia Moro 2014: post-hoc

2. **Balance (12%)**

Perfil financiero crítico

3. **Age (8%)**

Demografía validada

Modelo Realista (sin duration):

AUC = 0.856 — Recall = 82%

Hallazgos de Importancia (CRISP-DM): Safarkhani (2021)

1. duration domina: 42% importancia, pero no disponible pre-llamada (proxy: histórico)
2. Variables macro estables: Euribor correlación 0.73 con ciclo económico
3. Accionables identificadas: campaign (frecuencia), mes (timing), poutcome (estrategia)

Validación Clasificación vs. Literatura

Estudio	Método	Accuracy
Este estudio	RF + SMOTE + T	94.39%
Safarkhani 2021	J48 + SMOTE + FS	94.39%
Moro et al. 2014	Neural Network	AUC 0.80
Akkaya 2024	NN (Orange)	98.66%*

*Posible sesgo de duration


Conclusión: **Reproducimos exactamente** Safarkhani (2021)

⇒ Validación de robustez metodológica

Validación de Originalidad (CRISP-DM)

1. Apriori no aplicado previamente: brecha metodológica identificada
2. Generalización validada: patrones consistentes con UCI datasets España/Portugal
3. Hallazgo original verificado: 10-fold CV + benchmark con estudios recientes

Reglas de Asociación (Apriori)



Agrawal & Srikant (1994). Proc. 20th VLDB

Insights Accionables (CRISP-DM): Reglas Apriori

1. Patrones identificados: reglas con $Lift > 4$ indican combinaciones efectivas
2. Reglas robustas: $Lift > 4 + Support > 0.05$ garantiza confiabilidad estadística
3. Segmentación accionable: perfiles con alta probabilidad de conversión

Top 3 Reglas (y=yes):

1. Lift = 4.68

{primary, may, Adult} → {blue-collar, married, yes}

2. Lift = 4.67

Similar perfil + balance low

3. Lift = 4.67

Variación con housing=no

Interpretación Lift=4.68:

Cliente **4.68x más probable** de suscribir

Validación Apriori: GAP Bibliográfico

Técnica	Estudios	Observación
Clasificación	5/5	Ampliamente explorado
Clustering	1/5	Solo Yan 2025
Apriori	0/5	GAP

¿Por qué este gap?

- Dataset predominantemente numérico (no transaccional)
- Foco en métricas predictivas (AUC), no descriptivas
- Requiere discretización inteligente

Nuestra Contribución: **Primera aplicación documentada**

de Apriori discretizado para Bank Marketing UCI

Posicionamiento (CRISP-DM)

Validamos reproducibilidad (Clustering, Clasificación) + **Aporte original** (Apriori)

Conclusiones y Recomendaciones

Hallazgos Clave:

1. **Segmentación:** 3 perfiles accionables (K-Means, Sil=0.097)
2. **Predicción:** RF optimizado captura 90% clientes (Recall)
3. **Patrones:** Reglas Apriori Lift>4.6 (blue-collar, casado, mayo)

Impacto Potencial:

- Reducción de llamadas innecesarias
- Mayor captura de clientes potenciales (90% Recall)
- Segmentación accionable por perfiles

Próximos Pasos: A/B Testing, NLP transcripciones, datos post-2010

3 Preguntas Finales (CRISP-DM)

1. ¿Cómo monitorear degradación del modelo en producción?
2. ¿Qué métricas de negocio evalúan éxito real?
3. ¿Cómo gestionar aspectos éticos/privacidad (GDPR)?

Referencias Bibliográficas

Referencias Principales Citadas:

1. **Moro, S., Cortez, P., & Rita, P. (2014).** A data-driven approach to predict the success of bank telemarketing. *Decision Support Systems*, 62, 22-31. DOI: 10.1016/j.dss.2014.03.001
2. **Safarkhani, F., & Moro, S. (2021).** Improving the Accuracy of Predicting Bank Depositor's Behavior Using a Decision Tree. *Applied Sciences*, 11(19), 9016. DOI: 10.3390/app11199016
3. **Yan, X., Li, Y., Nie, F., & Li, R. (2025).** Bank Customer Segmentation and Marketing Strategies Based on Improved DBSCAN Algorithm. *Applied Sciences*, 15(6), 3138. DOI: 10.3390/app15063138
4. **Akkaya, E., & Turgay, S. (2024).** Unveiling the Power: A Comparative Analysis of Data Mining Tools through Decision Tree Classification on the Bank Marketing Dataset. *WSEAS Transactions on Computers*, 23, 95-105. DOI: 10.37394/23205.2024.23.9
5. **Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002).** SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321-357.
6. **Agrawal, R., & Srikant, R. (1994).** Fast algorithms for mining association rules. *Proc. 20th Int. Conf. Very Large Data Bases (VLDB)*, 487-499.

Informe Técnico Completo:

Irribarra Aguilera, M. E. (2026). *Optimización de campañas de marketing bancario mediante técnicas de ciencia de datos: Análisis del dataset Bank Marketing. Trabajo del Magíster en Data Science, Universidad San Sebastián, Concepción, Chile.*