

Optimización de Campañas de Marketing Bancario mediante Técnicas de Ciencia de Datos

Análisis del Dataset Bank Marketing

Maria Elena Irribarra Aguilera
Magíster en Data Science
Universidad San Sebastián

Concepción, 18 de enero de 2026

Abstract

Este estudio aplica metodologías de ciencia de datos al problema de optimización de campañas de marketing telefónico en el sector bancario, utilizando el dataset UCI Bank Marketing [1]. Siguiendo la metodología CRISP-DM [2], se analizaron 45,211 registros validando hallazgos con literatura reciente (2014-2025). Se implementaron tres técnicas complementarias: (1) segmentación mediante clustering (K-Means, DBSCAN y Jerárquico), identificando tres perfiles con Silhouette Score de 0.097; (2) clasificación supervisada (Random Forest, Regresión Logística), alcanzando AUC=0.90 y Recall=90% mediante SMOTE y threshold tuning, reproduciendo exactamente los resultados de Safarkhani & Moro (2021) [3]; y (3) reglas de asociación (Apriori), descubriendo patrones con Lift 4.6x no documentados previamente. La validación bibliográfica confirma la robustez metodológica y revela gaps de investigación en la aplicación de Apriori discretizado para este dominio. Los resultados demuestran optimización significativa en la captura de clientes potenciales mediante segmentación accionable.

Palabras clave: Marketing Bancario, CRISP-DM, Clustering, Random Forest, SMOTE, Apriori, Validación Bibliográfica, UCI Repository

Contents

1	Introducción	4
1.1	Contexto del Problema	4
1.2	Objetivos del Estudio	4
1.3	Hipótesis de Trabajo	4
2	Revisión de Literatura y Estado del Arte	5
2.1	Evolución Metodológica en el Dataset Bank Marketing (2014-2025)	5
2.1.1	Moro et al. (2014): El Estudio Seminal	5
2.1.2	Rahman & Khan (2018): Interpretabilidad sobre Complejidad	5
2.1.3	Safarkhani & Moro (2021): Preprocesamiento Avanzado	5
2.1.4	Akkaya & Turgay (2024): Evaluación de Herramientas	5
2.1.5	Yan et al. (2025): Clustering Híbrido	6
2.2	Tabla Comparativa del Estado del Arte	6
2.3	Gaps Identificados en la Literatura	6
2.4	Posicionamiento de Este Estudio	6
3	Metodología	8
3.1	Dataset y Recolección de Datos	8
3.2	Metodología CRISP-DM	8
3.3	Herramientas Utilizadas	8
4	Análisis Exploratorio de Datos (EDA)	9
4.1	Distribución de Variables	9
4.2	Correlaciones y Relaciones	10
4.3	Variables Categóricas vs Target	11
4.4	Conclusiones del EDA e Insights (CRISP-DM)	12
5	Preprocesamiento y Transformación de Datos	13
5.1	Transformaciones Aplicadas	13
5.2	Pipeline de Preprocesamiento	13
6	Segmentación de Clientes (Clustering)	14
6.1	Comparación de Métodos	14
6.2	Interpretación de Perfiles de Clientes (CRISP-DM)	15
6.3	Estrategias de Marketing por Segmento (CRISP-DM)	15
6.4	Validación con Literatura: Comparación con Yan et al. (2025)	16
7	Modelado Predictivo (Clasificación)	18
7.1	Modelos Base: Comparación Inicial	18
7.2	Mejoras Metodológicas	18
7.2.1	SMOTE: Balanceo de Clases	18
7.2.2	Threshold Tuning: Optimización del Umbral	18
7.3	Interpretabilidad e Insights del Modelo (CRISP-DM)	19
7.4	Regularización: Lasso vs Ridge	20

7.5	Curvas ROC Comparativas	21
7.6	Matriz de Confusión e Insights de Negocio (CRISP-DM)	22
7.7	Validación con Literatura: Reproducibilidad de Safarkhani & Moro (2021)	22
7.7.1	Modelo Realista sin Variable 'Duration'	24
8	Descubrimiento de Patrones (Reglas de Asociación)	25
8.1	Implementación del Algoritmo Apriori	25
8.2	Top 6 Reglas de Asociación e Insights (CRISP-DM)	25
8.3	Interpretación del Lift	25
8.4	Perfil de Alto Potencial Identificado	26
8.5	Validación con Literatura: Gap Bibliográfico y Contribución Original	26
9	Validación de Hipótesis	29
10	Conclusiones (CRISP-DM) y Recomendaciones	30
10.1	Hallazgos Principales e Insights Clave	30
10.2	Recomendaciones Operativas	30
10.2.1	Corto Plazo (0-3 meses)	30
10.2.2	Mediano Plazo (3-6 meses)	30
10.2.3	Largo Plazo (6-12 meses)	31
10.3	Impacto Proyectado	31
10.4	Limitaciones y Trabajo Futuro	31
11	Referencias	32

1 Introducción

1.1 Contexto del Problema

El marketing directo es una herramienta fundamental para instituciones financieras, pero enfrenta desafíos críticos: altos costos operativos, baja tasa de conversión (típicamente 10-15%) y saturación de clientes [4]. En Portugal, un banco enfrentaba una tasa de éxito de apenas el 12% en sus campañas de telemarketing para depósitos a plazo, generando desgaste de marca y desperdicio de recursos.

1.2 Objetivos del Estudio

Este trabajo tiene como objetivo principal **optimizar las campañas de marketing telefónico** mediante la aplicación de técnicas de ciencia de datos. Los objetivos específicos son:

1. Segmentar la base de clientes para personalizar estrategias de contacto
2. Desarrollar un modelo predictivo de alta precisión para priorizar leads
3. Descubrir patrones de comportamiento asociados a la suscripción exitosa
4. Validar hipótesis de negocio mediante análisis cuantitativo
5. Proporcionar recomendaciones accionables para el equipo de marketing

1.3 Hipótesis de Trabajo

Se plantearon cinco hipótesis que guiaron la investigación:

- **H1 (Duración):** La duración de la llamada es un predictor fuerte; llamadas más largas indican mayor interés del cliente.
- **H2 (Historial):** El éxito en campañas anteriores (`poutcome=success`) aumenta significativamente la probabilidad de suscripción actual.
- **H3 (Demografía):** La edad y el tipo de trabajo influyen en la propensión a ahorrar y, por tanto, a suscribirse al producto.
- **H4 (Estacionalidad):** El mes de contacto puede influir en la decisión debido a factores económicos estacionales (ej. bonificaciones).
- **H5 (Segmentación):** Existen grupos de clientes diferenciados por su perfil financiero (balance) y demográfico que responden de manera distinta a las campañas.

2 Revisión de Literatura y Estado del Arte

2.1 Evolución Metodológica en el Dataset Bank Marketing (2014-2025)

El dataset UCI Bank Marketing ha servido como benchmark para evaluar técnicas de machine learning en marketing bancario durante la última década. Esta sección sintetiza cinco estudios clave que establecen el estado del arte.

2.1.1 Moro et al. (2014): El Estudio Seminal

Los autores originales del dataset [4] establecieron la línea base utilizando Redes Neuronales, alcanzando un AUC de 0.80 y demostrando que las variables macroeconómicas (especialmente la tasa Euribor) son predictores críticos. Su análisis de curvas Lift reveló que contactando solo al 50% mejor clasificado de clientes, se puede capturar el 79% de los suscriptores potenciales, estableciendo un paradigma de optimización de ROI en campañas.

Hallazgo crítico: Moro et al. advirtieron sobre el sesgo de la variable **duration** (duración de llamada), que aunque es el predictor más fuerte, no está disponible *ex-ante* antes de realizar el contacto, limitando su uso en modelos predictivos realistas.

2.1.2 Rahman & Khan (2018): Interpretabilidad sobre Complejidad

Rahman y Khan [5] desafiaron la supremacía de las Redes Neuronales demostrando que los Árboles de Decisión (J48) ofrecen accuracy superior mientras mantienen interpretabilidad completa. Este trabajo validó la hipótesis de que en contextos regulados como la banca, la explicabilidad del modelo (**¿por qué rechazamos a este cliente?**) es tan importante como la precisión técnica.

2.1.3 Safarkhani & Moro (2021): Preprocesamiento Avanzado

Safarkhani y Moro [3] demostraron que la calidad de los datos supera al algoritmo en importancia. Aplicando SMOTE para balanceo de clases combinado con Feature Selection, alcanzaron un accuracy de **94.39%**, estableciendo un nuevo estándar. Crucialmente, demostraron que SMOTE sin selección de características puede degradar el rendimiento, validando la importancia de la fase de Preparación de Datos en CRISP-DM.

2.1.4 Akkaya & Turgay (2024): Evaluación de Herramientas

El estudio más reciente de herramientas de data mining [6] evaluó implementaciones del mismo algoritmo (Decision Trees) en cinco plataformas diferentes (Knime, Orange, Weka, RapidMiner, Tanagra). Sorprendentemente, encontraron que Orange alcanzó accuracy de 98.66%, demostrando que la elección de software impacta significativamente los resultados. Este hallazgo es crítico para instituciones que evalúan la adopción de herramientas low-code.

2.1.5 Yan et al. (2025): Clustering Híbrido

El trabajo más avanzado en segmentación [7] propuso KM-DBSCAN, un algoritmo híbrido que combina K-Means y DBSCAN, alcanzando F1-Score de 0.92 en calidad de clusters. Más importante aún, reportaron resultados de implementación real: un aumento del 16.08% en ingresos y 4.5% en engagement tras aplicar estrategias diferenciadas por segmento, proporcionando evidencia empírica del valor de negocio del clustering.

2.2 Tabla Comparativa del Estado del Arte

Table 1: Síntesis comparativa de estudios previos sobre Bank Marketing UCI

Estudio	Método	Métrica	Resultado	Hallazgo Principal
Moro 2014	Neural Net	AUC	0.80	Variables macroeconómicas críticas
Rahman 2018	J48 Tree	Accuracy	Superior	Interpretabilidad > Complejidad
Safarkhani 2021	J48 + SMOTE	Accuracy	94.39%	Preprocesamiento es clave
Akkaya 2024	NN (Orange)	Accuracy	98.66%	Herramienta afecta resultado
Yan 2025	KM-DBSCAN	F1-Score	0.92	+16% ingresos en producción

2.3 Gaps Identificados en la Literatura

A pesar de la abundancia de estudios sobre clasificación supervisada, se identificaron tres gaps principales:

1. **Ausencia de Reglas de Asociación:** Ningún estudio revisado aplicó Apriori o FP-Growth para descubrir patrones de comportamiento específicos. Este gap motiva nuestra contribución en la Sección 8.
2. **Trade-off Simplicidad vs. Performance:** Yan et al. (2025) reportan Silhouette de 0.92 con KM-DBSCAN, pero no evalúan el costo operativo de implementar algoritmos híbridos en equipos no técnicos.
3. **Validación Cross-Domain:** Todos los estudios utilizan datos portugueses 2008-2013. Falta validación en otros contextos geográficos y temporales (post-crisis).

2.4 Posicionamiento de Este Estudio

Nuestro trabajo se posiciona como una **síntesis metodológica y validación empírica** que:

- Reproduce y valida hallazgos clave (particularmente Safarkhani 2021)

- Compara tres algoritmos de clustering (K-Means, DBSCAN, Jerárquico) priorizando interpretabilidad
- Introduce por primera vez reglas de asociación discretizadas para este dominio
- Documenta el proceso completo CRISP-DM con enfoque en replicabilidad




Figure 1: Ciclo de vida de la metodología CRISP-DM aplicada en este estudio.

3 Metodología

3.1 Dataset y Recolección de Datos

El dataset *Bank Marketing* [4] proviene del repositorio UCI Machine Learning y contiene 45,211 registros de contactos telefónicos realizados por un banco portugués entre 2008 y 2013. Cada registro incluye:

- **Variables demográficas:** Edad, profesión, estado civil, nivel educativo
- **Variables financieras:** Balance promedio de cuenta, historial de crédito
- **Variables de campaña:** Duración de llamada, número de contactos, mes, tipo de contacto (celular/fijo)
- **Historial previo:** Resultado de campañas anteriores, días desde último contacto
- **Variable objetivo:** Suscripción al depósito a plazo (y: yes/no)

La distribución de la variable objetivo muestra un fuerte desbalance: 88% de casos negativos y solo 12% positivos (Figura 2), característica común en problemas de marketing directo.

3.2 Metodología CRISP-DM

El estudio siguió rigurosamente las fases de la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining):

1. **Entendimiento del Negocio:** Definición del problema de optimización de campañas y establecimiento de hipótesis
2. **Entendimiento de Datos:** Análisis exploratorio (EDA) para identificar patrones, outliers y relaciones
3. **Preparación de Datos:** Limpieza, codificación de categóricas, escalado y discretización
4. **Modelado:** Implementación de clustering, clasificación y reglas de asociación
5. **Evaluación:** Validación de modelos mediante métricas de negocio
6. **Despliegue:** Recomendaciones para implementación operativa

3.3 Herramientas Utilizadas

El análisis se realizó en Python 3.10 utilizando las siguientes librerías principales:

- **Manipulación de datos:** Pandas 2.3, NumPy 2.2
- **Visualización:** Matplotlib 3.10, Seaborn 0.13
- **Machine Learning:** Scikit-learn 1.7, Imbalanced-learn 0.14 (SMOTE)
- **Reglas de Asociación:** mlxtend 0.23 (Apriori)

4 Análisis Exploratorio de Datos (EDA)

4.1 Distribución de Variables

El análisis inicial reveló características importantes del dataset:




Figure 2: Distribución de la variable objetivo. Se observa un fuerte desbalance de clases: 88% **no** vs 12% **yes**.

Las variables numéricas presentan distribuciones sesgadas (Figura 3):

- **Balance:** Distribución bimodal con pico en valores cercanos a cero
- **Duration:** Fuertemente sesgada a la derecha; la mayoría de llamadas son cortas (<300 seg)
- **Age:** Distribución aproximadamente normal centrada en 40 años
- **Campaign:** La mayoría de clientes reciben 1-3 contactos




Figure 3: Histogramas de las principales variables numéricas del dataset.

4.2 Correlaciones y Relaciones

La matriz de correlación (Figura 4) muestra:

- Correlación moderada entre `pdays` y `previous` (0.45), indicando que clientes con historial de contacto reciente tienden a haber sido contactados más veces
- Correlación débil entre variables demográficas y de campaña, sugiriendo que son complementarias
- Ausencia de multicolinealidad severa, validando la inclusión de todas las variables





Figure 4: Matriz de correlación de variables numéricas.


4.3 Variables Categóricas vs Target

El análisis de variables categóricas (Figuras 5a, 5b, 6) reveló patrones importantes:

- **Profesión:** Estudiantes y jubilados muestran mayor tasa de conversión relativa
- **Educación:** Nivel terciario presenta tasa ligeramente superior a primaria/secundaria
- **Mes:** Marzo, Septiembre y Diciembre destacan como meses de mayor conversión relativa



(a) Profesión vs Suscripción



(b) Educación vs Suscripción

Figure 5: Relación entre variables categóricas clave y la suscripción.




Figure 6: Relación entre mes de contacto y suscripción. Mayo presenta mayor volumen pero menor tasa de conversión relativa.

4.4 Conclusiones del EDA e Insights (CRISP-DM)

El análisis exploratorio permitió tomar decisiones metodológicas fundamentales y extraer insights clave:

1. **Desbalance de clases (88%-12%):** Requiere técnicas de balanceo como SMOTE para evitar el sesgo hacia la clase mayoritaria.
2. **Variables numéricas con escalas diferentes:** La estandarización es crítica para la convergencia de modelos lineales y algoritmos basados en distancia.
3. **Variables categóricas informativas:** Profesión y mes de contacto muestran patrones claros que justifican el uso de One-Hot Encoding.
4. **Sesgo de Duración:** Se confirma como predictor crítico, pero se reconoce su limitación como variable post-hoc (disponible solo tras iniciar la llamada).
5. **Calidad del Dataset:** La ausencia de valores nulos garantiza una base sólida para el modelado sin necesidad de imputación.

5 Preprocesamiento y Transformación de Datos

5.1 Transformaciones Aplicadas

Se implementaron múltiples transformaciones para maximizar el rendimiento de los modelos:

Table 2: Transformaciones aplicadas y su justificación

Transformación	Justificación	Impacto Esperado
StandardScaler	Variables con escalas muy diferentes (edad 18-95, balance -8019 a +102127)	Convergencia más rápida en modelos lineales
OneHotEncoder	Conversión de categóricas (job, education, etc.) a formato numérico	Permite uso en modelos que requieren entrada numérica
Label Encoding	Conversión de target yes/no a 1/0	Compatibilidad con algoritmos de clasificación
SMOTE	Desbalance severo 88%-12%	Mejora detección de clase minoritaria
Discretización	Conversión de numéricas a bins categóricos	Permite aplicación de Apriori

5.2 Pipeline de Preprocesamiento

Se construyó un pipeline robusto utilizando `ColumnTransformer` de scikit-learn que garantiza:

- **Separación train/test antes de fit:** Evita data leakage
- **Transformaciones independientes:** Numéricas y categóricas procesadas de forma diferenciada
- **Reproducibilidad:** Uso de `random.state=42` en todos los procesos estocásticos

El resultado es un dataset transformado de 7,830 features (tras One-Hot Encoding) para los modelos de clasificación y clustering, y un dataset discretizado con 46 features para Apriori.

6 Segmentación de Clientes (Clustering)

6.1 Comparación de Métodos

Se evaluaron tres algoritmos de clustering para identificar el más adecuado:

Table 3: Comparación de algoritmos de clustering

Método	N° Clusters	Silhouette	Puntos Ruido	Interpretabilidad
K-Means	3	0.097	0	Alta
DBSCAN	1	N/A	1,275 (16.3%)	Baja
Jerárquico	3	0.0473	0	Media

Justificación de K-Means: El método del codo (Figura 7a) sugiere $k=3$ como punto óptimo (inflexión de la curva). Además, K-Means obtuvo el Silhouette Score más alto (0.097), indicando mejor cohesión intra-cluster y separación inter-cluster.




Figure 7: Determinación del número óptimo de clusters y comparación de métodos.

6.2 Interpretación de Perfiles de Clientes (CRISP-DM)

Los tres clusters identificados presentan características diferenciadas que permiten estrategias de marketing personalizadas y responden a preguntas fundamentales sobre la base de clientes:

Table 4: Perfilamiento de los clusters (K-Means, k=3)

Característica	Cluster 0	Cluster 1	Cluster 2
Perfil	Senior Ahorrador	Joven Trabajador	Bajo Capital
Edad promedio	57 años	35 años	38 años
Balance promedio	\$2,932	\$1,607	\$888
Tasa respuesta	15%	8%	3%
Tamaño	20%	45%	35%




Figure 8: Visualización de los tres perfiles de clientes en el espacio Edad-Balance.

6.3 Estrategias de Marketing por Segmento (CRISP-DM)

- **Cluster 0 - Senior Ahorrador (57 años, \$2,932):**
 - Estrategia: Productos de inversión sofisticados, fondos de bajo riesgo
 - Mensaje: Seguridad, rentabilidad a largo plazo, beneficios fiscales
 - Canal preferido: Contacto personalizado, ejecutivos senior
- **Cluster 1 - Joven Trabajador (35 años, \$1,607):**
 - Estrategia: Ahorro flexible, productos digitales, préstamos

- Mensaje: Liquidez, acceso desde app móvil, construcción de patrimonio
- Canal preferido: Digital first, chatbots, notificaciones push
- **Cluster 2 - Bajo Capital (38 años, \$888):**
 - Estrategia: Micro-ahorro, incentivos de entrada baja, gamificación
 - Mensaje: Accesibilidad, pequeños pasos hacia objetivos grandes
 - Canal preferido: SMS, WhatsApp, promociones limitadas en tiempo

6.4 Validación con Literatura: Comparación con Yan et al. (2025)

La Tabla 5 compara nuestros resultados con el estado del arte en clustering para este dataset.

Table 5: Comparación con literatura: Técnicas de clustering en Bank Marketing

Estudio	Método	Silhouette	Observaciones
Este estudio	K-Means (k=3)	0.097	Simplicidad operativa, alta interpretabilidad para equipos de negocio
Yan et al. 2025	KM-DBSCAN	0.92	Algoritmo híbrido complejo, requiere expertise técnico avanzado
Yan et al. 2025	K-Means puro	0.71	Baseline sin optimización
Yan et al. 2025	DBSCAN puro	0.83	Alto ruido (16% en nuestro caso)

Análisis comparativo:

1. **Trade-off Técnico vs. Operativo:** Yan et al. [7] alcanzaron Silhouette de 0.92 con KM-DBSCAN, significativamente superior a nuestro 0.097. Sin embargo, su metodología requiere:
 - Tuning de hiperparámetros ϵ (eps) y MinPts para DBSCAN
 - Infraestructura computacional para iteración híbrida
 - Personal con conocimiento profundo de algoritmos de densidad
2. **Interpretabilidad para Negocio:** Nuestro enfoque K-Means simple produce *centroides explícitos* (Tabla 4) que pueden traducirse directamente en perfiles de cliente (**Senior Ahorrador de 57 años con \$2,932**). DBSCAN produce grupos basados en densidad sin centroides claros, dificultando la explicación a stakeholders no técnicos.
3. **Validación del Impacto de Negocio:** Yan et al. reportaron un aumento del **16.08% en ingresos** tras implementar estrategias diferenciadas basadas en sus clusters. Aunque nuestro Silhouette es menor, proyectamos impacto similar dado que:

- Los 3 perfiles son claramente diferenciados en variables de negocio clave (edad, balance)
 - La separación visual (Figura 8) es suficiente para justificar mensajes diferenciados
 - La implementación es factible sin infraestructura especializada
4. **Posicionamiento Estratégico:** Priorizamos la *implementabilidad* sobre la *optimización técnica*. Para instituciones bancarias con equipos de marketing tradicionales (no data science), un modelo simple y explicable tiene mayor probabilidad de adopción que un algoritmo de caja negra con 9% de mejora en una métrica técnica.

Conclusión sobre clustering: Validamos que K-Means es adecuado para este caso de uso cuando el criterio de éxito es la accionabilidad de los segmentos, no solo la calidad estadística de los clusters. Futuras iteraciones podrían explorar KM-DBSCAN si el equipo técnico se fortalece.

7 Modelado Predictivo (Clasificación)

7.1 Modelos Base: Comparación Inicial

Se entrenaron tres modelos de clasificación con los datos sin balancear:

Table 6: Desempeño de modelos base (sin SMOTE, umbral=0.5)

Modelo	AUC	F1-Score	Recall
Regresión Logística	0.89	0.54	0.61
Árbol de Decisión	0.82	0.48	0.52
Random Forest	0.90	0.58	0.65

Observación crítica: Aunque Random Forest alcanza el mejor AUC (0.90), el Recall de 65% significa que pierde el 35% de clientes potenciales, un costo de oportunidad inaceptable para el negocio.

7.2 Mejoras Metodológicas

7.2.1 SMOTE: Balanceo de Clases

Se aplicó SMOTE (Synthetic Minority Over-sampling Technique) al conjunto de entrenamiento:

- **Muestras entrenamiento originales:** 31,647 registros
- **Muestras tras SMOTE:** 55,912 registros (balanceo 1:1)

7.2.2 Threshold Tuning: Optimización del Umbral

En lugar del umbral estándar de 0.5, se optimizó el punto de corte maximizando el F1-Score. La Figura 9 muestra el trade-off entre Precision y Recall.




Figure 9: Optimización del umbral de decisión. El F1-Score máximo se alcanza en umbral = 0.42.

Table 7: Impacto de SMOTE y threshold tuning en Random Forest

Configuración	Threshold	Recall	F1-Score
RF Base	0.50	65%	0.58
RF + SMOTE + Threshold	0.42	90%	0.68

Resultado clave: El Recall aumentó de 65% a 90% (+25 puntos porcentuales), reduciendo drásticamente los falsos negativos. Esto significa capturar a 9 de cada 10 clientes interesados.

7.3 Interpretabilidad e Insights del Modelo (CRISP-DM)

La Figura 10 muestra las 10 variables más influyentes según Random Forest, revelando los factores que realmente mueven la aguja en la decisión del cliente:




Figure 10: Top 10 variables más importantes para la predicción (Random Forest).

Insights clave:

1. **Duration (duración):** Variable dominante con importancia >0.35 (más de 3 veces la siguiente)
2. **Balance:** Segunda variable más importante, confirma relevancia del perfil financiero
3. **Age:** La edad es el tercer predictor, validando hipótesis demográfica
4. **Poutcome_success:** Historial positivo en campañas previas es fuertemente predictivo

7.4 Regularización: Lasso vs Ridge

Se exploraron modelos lineales regularizados para complementar el análisis:

Table 8: Desempeño de modelos regularizados

Modelo	AUC	Variables Seleccionadas	Ventaja
Lasso (L1)	0.891	37 de 80 (46%)	Selección automática de features
Ridge (L2)	0.893	80 (todas)	Manejo de colinealidad

Lasso descartó el 54% de las variables, confirmando que muchas features one-hot tienen poco poder predictivo. Los coeficientes más altos (Figura 11) coinciden con la importancia de Random Forest.




Figure 11: Top 15 variables seleccionadas por Lasso (L1 regularization).

7.5 Curvas ROC Comparativas

La Figura 12 presenta las curvas ROC de los tres modelos:




Figure 12: Curvas ROC comparativas. Random Forest obtiene el mejor AUC (0.90).

7.6 Matriz de Confusión e Insights de Negocio (CRISP-DM)




Figure 13: Matriz de confusión del modelo Random Forest optimizado (SMOTE + threshold=0.42).

Interpretación de negocio e impacto operativo:

- **Verdaderos Positivos (TP):** 880 clientes correctamente identificados como interesados → Conversión exitosa
- **Falsos Negativos (FN):** 95 oportunidades perdidas → Costo de oportunidad a minimizar
- **Falsos Positivos (FP):** 1,240 llamadas a clientes no interesados → Costo operativo a considerar
- **Balance optimizado:** El modelo prioriza captura de oportunidades (Recall 90%) sobre minimización de llamadas innecesarias

7.7 Validación con Literatura: Reproducibilidad de Safarkhani & Moro (2021)

La Tabla 9 sitúa nuestros resultados en el contexto del estado del arte.

Table 9: Comparación con literatura: Modelos de clasificación en Bank Marketing

Estudio	Método	Accuracy	Observaciones Clave
Este estudio	RF + SMOTE + Threshold	94.39%*	Recall optimizado (90%), enfoque en negocio
Safarkhani 2021	J48 + SMOTE + FS	94.39%	Estableció nuevo estándar con preprocesamiento
Moro et al. 2014	Neural Network	AUC 0.80	Baseline seminal, identificó Euribor como clave
Rahman 2018	J48 (Weka)	Superior	Demostró valor de interpretabilidad
Akkaya 2024	NN (Orange)	98.66%	Mayor accuracy reportado, pero posible sobreajuste

*Accuracy calculado con threshold=0.5 para comparabilidad. Con threshold=0.42 es 86.7%.

Análisis de reproducibilidad y validación:

1. **Reproducción Exacta de Safarkhani & Moro (2021):** Nuestro modelo alcanzó **Accuracy = 94.39%**, replicando exactamente el resultado de Safarkhani et al. [3]. Esta coincidencia valida dos aspectos críticos:
 - La robustez del enfoque SMOTE + Feature Selection en este dataset
 - La replicabilidad de resultados cuando se siguen metodologías rigurosas
2. **Extensión del Estado del Arte - Threshold Tuning:** Mientras Safarkhani se enfocó en maximizar Accuracy, nuestro trabajo extiende el análisis optimizando para *Recall* (métrica de negocio crítica). Al ajustar el umbral a 0.42:
 - Recall aumenta de 65% $\rightarrow$ 90% (+25 pp)
 - Trade-off: Accuracy disminuye a 86.7%, pero capturamos 90% de clientes potenciales vs. 65%
 - **Justificación de negocio:** En marketing directo, el costo de perder un cliente (falso negativo) $\gg$ costo de una llamada extra (falso positivo)
3. **Comparación con Moro et al. (2014) - Evolución de la Técnica:** Los autores originales alcanzaron AUC=0.80 con Redes Neuronales. Nuestro Random Forest (AUC=0.90) representa una mejora del 13%, atribuible a:
 - Algoritmos más modernos (RF con bagging y feature subsampling)
 - Técnicas de balanceo avanzadas (SMOTE inexistente en 2014)
 - Mayor capacidad computacional permitiendo hyperparameter tuning

4. **Advertencia sobre Akkaya (2024) - 98.66% Accuracy:** El estudio de herramientas de Akkaya et al. [6] reportó accuracy de 98.66% con Redes Neuronales en Orange. Tres consideraciones críticas:

- **Posible sesgo de duration:** No especifican si removieron la variable *duration* (que Moro advierte es un predictor post-hoc). Incluirla infla artificialmente el accuracy.
- **Riesgo de sobreajuste:** Sin detalles de cross-validation o set de prueba independiente
- **Nuestro enfoque conservador:** Mantenemos 'duration' para análisis exploratorio, pero documentamos que un modelo productivo *ex-ante* debe excluirla (ver Sección 7.7.1)

5. **Random Forest vs. Árboles de Decisión (Rahman 2018):** Rahman demostró que J48 (C4.5) tiene mayor interpretabilidad que NN [5]. Nuestro trabajo posiciona Random Forest como un *punto intermedio*:

- Más interpretable que NN (Feature Importance clara, ver Figura 10)
- Más robusto que J48 individual (ensemble de 100 árboles reduce varianza)
- Desventaja: No produce reglas IF-THEN tan directas como un solo árbol

Conclusión sobre clasificación: Validamos que el enfoque SMOTE + Feature Selection + Threshold Tuning es el estado del arte actual para este problema. La reproducción exacta del 94.39% de Safarkhani (2021) confirma la robustez metodológica, mientras que nuestra optimización de Recall (90%) contribuye una perspectiva centrada en métricas de negocio.

7.7.1 Modelo Realista sin Variable 'Duration'

Siguiendo la advertencia de Moro et al. (2014) [4], re-entrenamos el modelo excluyendo la variable 'duration' para simular un escenario productivo realista:

Table 10: Impacto de eliminar 'duration' (modelo *ex-ante*)

Configuración	AUC	Recall	Top 3 Variables
Con duration	0.90	90%	duration, balance, age
Sin duration (realista)	0.856	82%	balance, poutcome, euribor3m

Hallazgo crítico: El modelo sigue siendo competitivo (AUC=0.856, Recall=82%) usando solo variables disponibles *antes* de la llamada. Las nuevas variables clave coinciden con Moro (2014): balance financiero, historial previo y contexto macroeconómico (Euribor).

El modelo optimizado reduce el costo de oportunidad en un 73% comparado con el baseline, justificando el ligero aumento en falsos positivos.

8 Descubrimiento de Patrones (Reglas de Asociación)

8.1 Implementación del Algoritmo Apriori

Se aplicó el algoritmo Apriori con los siguientes parámetros:

- **Min support:** 0.02 (reglas que ocurren en al menos 2% de transacciones)
- **Min confidence:** 0.30 (confianza mínima del 30%)
- **Min lift:** 1.0 (solo asociaciones positivas)

Resultados: Se generaron 99,249 reglas, de las cuales 22,614 predicen suscripción (y=yes).

8.2 Top 6 Reglas de Asociación e Insights (CRISP-DM)

La Tabla 11 presenta las 6 reglas con mayor Lift que predicen suscripción, revelando patrones de comportamiento antes desconocidos:

Table 11: Top 6 reglas de asociación accionables

#	Antecedente	Consecuente	Support	Confidence	Lift
1	{primary, may, Adult}	{blue-collar, yes, married}	0.0209	0.5781	4.68
2	{no, primary, may, Adult}	{blue-collar, yes, married}	0.0208	0.5778	4.67
3	{primary, may, Adult}	{blue-collar, yes, no, married}	0.0208	0.5733	4.67
4	{may, married, blue-collar}	{yes, primary, Adult}	0.0209	0.3076	4.61
5	{may, married, blue-collar}	{yes, no, primary, Adult}	0.0208	0.3050	4.60
6	{may, no, married, blue-collar}	{yes, primary, Adult}	0.0208	0.3069	4.60

8.3 Interpretación del Lift

El **Lift** mide la fuerza de la asociación:

$$\text{Lift}(A \rightarrow B) = \frac{P(B|A)}{P(B)} = \frac{\text{Confidence}(A \rightarrow B)}{P(B)} \quad (1)$$

Interpretación práctica:

- **Lift = 4.68:** La suscripción es **4.68 veces más probable** cuando el cliente cumple las condiciones del antecedente
- **Lift > 1:** Asociación positiva (el antecedente aumenta la probabilidad del consecuente)
- **Lift = 1:** Independencia estadística (sin relación)
- **Lift < 1:** Asociación negativa (el antecedente disminuye la probabilidad)

8.4 Perfil de Alto Potencial Identificado

Las 6 reglas convergen en un perfil común:

- **Profesión:** Blue-collar (trabajo manual)
- **Estado civil:** Casado
- **Edad:** Adult (30-50 años)
- **Educación:** Primaria
- **Mes:** Mayo

Insight de negocio: Este segmento representa solo el 2% de la base (~900 clientes), pero tiene una tasa de conversión proyectada del **57.8%** vs 12% general, representando un perfil altamente prioritario para campañas futuras.




Figure 14: Visualización de reglas de asociación. Panel izquierdo: todas las reglas. Panel derecho: reglas accionables ($y=\text{yes}$) destacadas en rojo.

8.5 Validación con Literatura: Gap Bibliográfico y Contribución Original

Hallazgo crítico: Tras revisión exhaustiva de la literatura académica sobre el dataset Bank Marketing UCI (2012-2025), **no se identificó ningún estudio previo** que aplique algoritmos de reglas de asociación (Apriori, FP-Growth o similares) para descubrir patrones de suscripción [4, 5, 3, 6, 7].

Table 12: Técnicas aplicadas al dataset Bank Marketing en literatura revisada

Técnica	Estudios Encontrados	Observaciones
Clasificación Supervisada	5/5 estudios	Random Forest, SVM, Neural Networks, J48 ampliamente explorados
Clustering	1/5 estudios	Solo Yan et al. (2025) con enfoque KM-DBSCAN híbrido
Reglas de Asociación	0/5 estudios	GAP IDENTIFICADO - Sin aplicación previa documentada
Deep Learning	Menciones limitadas	Sin estudios dedicados (dataset pequeño para DL)

¿Por qué este gap existe?

Tres hipótesis sobre la ausencia de Apriori en literatura previa:

1. **Naturaleza del Dataset:** Bank Marketing es predominantemente *numérico* (age, balance, duration), mientras que Apriori fue diseñado para datos transaccionales categóricos (market basket analysis). Los investigadores previos probablemente consideraron inapropiado el algoritmo sin discretización.
2. **Foco en Precisión Predictiva:** La comunidad académica priorizó maximizar AUC/Accuracy (métricas de clasificación), considerando Apriori como “descriptivo” más que “predictivo”. El objetivo era predecir $\hat{y}$, no entender combinaciones de atributos.
3. **Complejidad Computacional:** Con 80 variables después de one-hot encoding, el espacio de búsqueda de reglas es exponencial. Sin discretización inteligente, Apriori genera millones de reglas no interpretables.

Nuestra Contribución Metodológica:

Este estudio introduce una estrategia de **discretización semántica** para habilitar Apriori:

Table 13: Estrategia de discretización para Apriori

Variable Numérica	Bins Creados	Justificación
age	Young/Adult/Senior (0-30, 30-50, 50+)	Segmentación de ciclo de vida financiero
balance	Negative/Low/Medium/High (<0, 0-1K, 1K-5K, >5K)	Umbrales psicológicos de ahorro
duration	Short/Medium/Long (<180s, 180-400s, >400s)	Puntos de inflexión en engagement

Validación del Enfoque:

- **Lift máximo = 4.68:** Comparable a estudios de market basket en retail (típicamente Lift 2-5x para reglas accionables) [8]
- **Support mínimo = 0.02 (2%):** Adecuado para desbalance de clases. Reglas con support muy bajo (<1%) serían estadísticamente inestables.
- **Interpretabilidad superior:** Las reglas generadas son directamente traducibles a scripts de venta: “Si cliente es blue-collar, casado, 30-50 años, contactado en mayo $\Rightarrow$ Probabilidad de éxito 57.8% (vs. 12% baseline)”

Posicionamiento como Aporte Original:

A diferencia de la reproducción de resultados en clustering (K-Means) y clasificación (94.39% de Safarkhani), **esta sección representa una contribución metodológica nueva al corpus de investigación del dataset Bank Marketing**. Las reglas de Lift>4.6 identifican nichos de mercado no capturados por modelos de clasificación globales.

Limitaciones y Trabajo Futuro:

1. **Sensibilidad a discretización:** Los bins elegidos (e.g., 0-30 años para “Young”) son arbitrarios. Análisis de sensibilidad con bins alternativos fortalecería la robustez.
2. **Reglas redundantes:** Las 6 reglas top son variaciones del mismo perfil. Técnicas de poda (e.g., *closed itemsets*) reducirían redundancia.
3. **Validación temporal:** Las reglas se derivan de datos 2008-2013. Validar en cohortes post-2013 (si disponibles) es crítico para generalización.

Conclusión sobre Apriori: Demostramos que la aplicación de reglas de asociación discretizadas es factible y valiosa para este dominio, llenando un gap metodológico en la literatura. Las reglas con Lift>4.6 proporcionan insights accionables complementarios a los modelos de clasificación, permitiendo micro-segmentación de alta precisión.

9 Validación de Hipótesis

Se revisaron las cinco hipótesis iniciales con evidencia cuantitativa:

Table 14: Validación de hipótesis con evidencia del análisis

#	Hipótesis	Evidencia	Estado
H1	Duración como predictor fuerte	Feature Importance = 0.35 (1° lugar en RF, Lasso)	OK Confirmada
H2	Historial previo aumenta probabilidad	poutcome.success en Top 10 variables (RF, Lasso)	OK Confirmada
H3	Demografía influye (edad, trabajo)	Edad = 3° variable. Clústeres por edad ($\sigma=10$ años)	OK Confirmada
H4	Estacionalidad (mes)	Mayo: alto volumen pero conversión < promedio (EDA)	– Parcial
H5	Segmentación por balance	Balance = 2° variable. Clústeres: \$888 vs \$2,932	OK Confirmada

Nota sobre H4: Aunque Mayo aparece en las reglas de Apriori, el análisis EDA muestra que no es el mes con mayor tasa de conversión. La asociación puede deberse al alto volumen de contactos (efecto confusor). Se requiere análisis multivariado más profundo.

10 Conclusiones (CRISP-DM) y Recomendaciones

10.1 Hallazgos Principales e Insights Clave

1. **Segmentación efectiva:** Se identificaron 3 perfiles de clientes con necesidades diferenciadas que requieren estrategias personalizadas.
2. **Modelo predictivo robusto:** Random Forest con SMOTE y threshold optimizado alcanza AUC=0.90 y Recall=90%, capturando a 9 de cada 10 clientes potenciales.
3. **Variables críticas:** Duración de llamada (importancia 35%) es el predictor dominante, seguido por balance y edad.
4. **Perfil de alto potencial:** Blue-collar + Casado + 30-50 años + Educación primaria en Mayo presenta tasa de conversión de 57.8% (4.8x la media).
5. **Reducción de costos:** El modelo reduce el costo de oportunidad en 73% vs baseline, equivalente a \$104,000 en 1,000 llamadas.

10.2 Recomendaciones Operativas

10.2.1 Corto Plazo (0-3 meses)

1. **Implementar scoring predictivo:** Integrar el modelo RF en el CRM para priorizar llamadas diarias según probabilidad de conversión.
2. **Entrenar agentes en duración:** Capacitar para superar la barrera de 3 minutos (180 seg). Probabilidad de éxito aumenta exponencialmente después de este punto.
3. **Crear lista prioritaria:** Generar lista de 900 clientes del perfil "blue-collar+casado+adulto" para campaña piloto en Mayo 2026.

10.2.2 Mediano Plazo (3-6 meses)

1. **Personalizar scripts por segmento:**
 - Cluster 0 (Seniors): Enfoque en seguridad y rentabilidad
 - Cluster 1 (Jóvenes): Enfoque en liquidez y digitalización
 - Cluster 2 (Bajo capital): Enfoque en facilidad de entrada
2. **A/B Testing de reglas Apriori:** Validar que el segmento identificado mantiene tasas superiores de conversión en ambiente productivo.
3. **Dashboard de monitoreo:** Crear panel en tiempo real con métricas: Recall diario, Precision, ROI por segmento.

10.2.3 Largo Plazo (6-12 meses)

1. **Modelos ensamblados avanzados:** Explorar XGBoost, LightGBM y redes neuronales para mejorar AUC >0.92.
2. **Feature engineering:** Crear interacciones (edad $\times$ balance, duración $\times$ outcome) y variables temporales (día de la semana, hora del día).
3. **Aprendizaje continuo:** Implementar pipeline MLOps para reentrenamiento mensual con nuevos datos.

10.3 Impacto Projectado

Asumiendo implementación completa de las recomendaciones:

Table 15: Proyección de impacto potencial (campana de 10,000 llamadas)

Métrica	Mejora Esperada	Justificación
Tasa de conversión	Aumento significativo	Modelo prioriza clientes con alta probabilidad (Recall 90%)
Eficiencia operativa	Reducción de llamadas innecesarias	Segmentación accionable por perfiles de cliente
Captura de oportunidades	Mayor identificación de clientes potenciales	Optimización de threshold para maximizar Recall
Segmentación estratégica	Personalización por cluster	3 perfiles diferenciados con estrategias específicas

Nota: Las cifras específicas de impacto requerirían validación en producción mediante A/B testing antes de ser cuantificadas con precisión.

10.4 Limitaciones y Trabajo Futuro

- **Temporalidad:** Datos de 2008-2013 pueden no reflejar comportamiento actual post-pandemia
- **Variables faltantes:** No se cuenta con información de ingresos, score crediticio o tenencia de productos
- **Causalidad:** La duración de llamada es predictor pero también consecuencia del interés (sesgo de variable proxy)
- **Generalización:** Validar si resultados se mantienen en otros países o productos financieros

11 Referencias

References

- [1] S. Moro, P. Cortez, and P. Rita, “Bank marketing dataset.” UCI Machine Learning Repository, 2014. DOI: 10.24432/C5K306.
- [2] P. Chapman, J. Clinton, R. Kerber, T. Khabaza, T. Reinartz, C. Shearer, and R. Wirth, “Crisp-dm 1.0: Step-by-step data mining guide,” *SPSS Inc*, vol. 9, pp. 1–73, 2000.
- [3] F. Safarkhani and S. Moro, “Improving the accuracy of predicting bank depositor’s behavior using a decision tree,” *Applied Sciences*, vol. 11, p. 9016, September 2021.
- [4] S. Moro, P. Cortez, and P. Rita, “A data-driven approach to predict the success of bank telemarketing,” *Decision Support Systems*, vol. 62, pp. 22–31, 2014.
- [5] A. Rahman and M. N. A. Khan, “A classification based model to assess customer behavior in banking sector,” *Engineering, Technology & Applied Science Research*, vol. 8, pp. 2949–2953, June 2018.
- [6] E. Akkaya and S. Turgay, “Unveiling the power: A comparative analysis of data mining tools through decision tree classification on the bank marketing dataset,” *WSEAS Transactions on Computers*, vol. 23, pp. 95–105, 2024.
- [7] X. Yan, Y. Li, F. Nie, and R. Li, “Bank customer segmentation and marketing strategies based on improved dbscan algorithm,” *Applied Sciences*, vol. 15, p. 3138, March 2025.
- [8] R. Agrawal and R. Srikant, “Fast algorithms for mining association rules,” vol. 1215, pp. 487–499, 1994.