



UNIVERSIDAD
SAN SEBASTIAN
VOCACIÓN POR LA EXCELENCIA



Taller de aplicaciones

Magister en Data science
Facultad de Ingeniería

Docente: Dr. Mauricio Sepúlveda

SEDE
SANTIAGO
Campus Bellavista

Asignatura: Taller de aplicaciones

II. DESCRIPCIÓN

Módulo teórico-práctico remoto sincrónico, que proporciona al estudiante un **escenario real para la aplicación de técnicas y algoritmos avanzados de Data Science**, generando en él habilidades y destrezas desarrolladas por la interacción con problemáticas contingentes. Estos conocimientos y habilidades le permiten realizar **consultorías en áreas transversales de la sociedad**, como salud, educación, minería, industria, entre otros.

Se espera que el estudiante muestre disposición al **trabajo en equipo, empatía, solidaridad, honestidad y proactividad, prolijidad, rigurosidad** en el desarrollo de su trabajo.

IV. RESULTADO DE APRENDIZAJE GENERAL DEL MÓDULO

Desarrolla una **consultoría**, por medio de la entrega de informes con **técnicas avanzadas de la ciencia de datos**, para la toma de decisiones.

Electivo para:

- Magister Ing Industrial
- Data science
- Dirección de operaciones, Logística y distribución
- Gestión de la construcción y sustentabilidad



Unidad 1: Consultoría Supervisada

Resultado de aprendizaje	Aplica las técnicas de la ciencia de datos en un caso real, para extraer conocimiento y tomar decisiones bajo incertidumbre.
--------------------------	--

Contenidos

- Métodos usados para la extracción de conocimiento
- Planificación del proyecto
- Recolección de la información
- Procesamiento de la información

Evaluación grupal 60%, máximo dos personas.

Trabajo de Aplicación

Unidad 2: CONSTRUCCIÓN DE INFORMES Y DASHBOARD INTERACTIVOS

Resultado de aprendizaje	2.1. Presenta la información por medio de informes técnicos, exposiciones orales y paneles de control, permitiendo la toma de decisiones en base a sus resultados.
--------------------------	--

Contenidos

- Creación de informes y reportes en Tableau
- Creación de informes y reportes en Tableau
- Creación de Dashboard con Plotly y Dash
- Creación de Dashboard Power BI
- Creación de Dashboard Tableau

Evaluación grupal 40%, máximo dos personas.

Trabajo de Aplicación

Planificación del curso

Clase 1 (19/Diciembre/2025 Viernes 16:30-21:45)

- Métodos usados para la extracción de conocimiento:
 - Agrupamiento
 - Clasificación
 - Asociación
 - Otros

Clase 2 (9/Enero/2026 Viernes 16:30-21:45)

- Planificación del proyecto
- Recolección de la información
- Procesamiento de la información

Trabajo de Aplicación: Desarrollo de un experimento con **datos reales** de Data science.

Conceptos más relevantes

Ciencia de datos: es un campo interdisciplinario que utiliza métodos científicos, procesos, algoritmos y sistemas para extraer conocimiento e información de datos estructurados y no estructurados.



DATA SCIENCE



BUSINESS INTELLIGENCE



ANALYTICS



BIG DATA

Analítica o (Business Analytics): Similar a BI, pero se centra en el análisis predictivo y prescriptivo (resumir y entender el pasado). "¿por qué pasó?", "¿qué pasará?" y "¿qué debemos hacer?"

Business intelligence: Hace referencia a un conjunto de productos y servicios para acceder a los datos, analizarlos y convertirlos en información. La misión consiste en mejorar el proceso de toma de decisiones en los negocios basándose en los datos corporativos. Considera "¿qué pasó?" y "¿qué está pasando?"

Big data: Es un conjunto de tecnologías que permiten la recopilación, almacenamiento, gestión, análisis y visualización, potencialmente en condiciones de tiempo real, de grandes conjuntos de datos con características heterogéneas.

Métodos usados para la extracción de conocimiento

- Clustering/agrupación
- Clasificación
- Descubrimiento de patrones (reglas de asociación)
- Estimación
- Pronóstico
- Minería de texto

Métodos usados para la extracción de conocimiento


- Clustering/agrupación
- Clasificación
- Descubrimiento de patrones (reglas de asociación)
- Estimación
- Pronostico
- Minería de texto

Durante el curso NO explicaremos en detalle el algoritmo de las distintas técnicas. Eso lo manejan los científicos de datos, quienes incluso crean y combinan sus propias técnicas.

=> Nos enfocaremos en comprenderlo, su utilidad, uso y resultados.

Agrupamiento

Agrupar un conjunto de datos en grupos o clústeres que compartan características similares entre sí, pero sean diferentes de los grupos vecinos.



	id	sexo	fechnac	educ	catlab	salario	salini	T.emp	expprev	minoría
Grupo 1	121	Mujer	6-ago-1936	15	Administrativo	\$18.750	\$10.500	90	54	No
	122	Mujer	26-sep-1965	15	Administrativo	\$32.550	\$13.500	90	22	No
	123	Mujer	24-abr-1949	12	Administrativo	\$33.300	\$15.000	90	3	No
	124	Mujer	29-may-1963	16	Administrativo	\$38.550	\$16.500	90	Ausente	No
	125	Hombre	6-ago-1956	12	Administrativo	\$27.450	\$15.000	90	173	Sí
Grupo 2	126	Hombre	21-ene-1951	15	Seguridad	\$24.300	\$15.000	90	191	Sí
	127	Hombre	1-sep-1950	12	Seguridad	\$30.750	\$15.000	90	209	Sí
Grupo 3	128	Mujer	25-jul-1946	12	Administrativo	\$19.650	\$9.750	90	229	Sí
	129	Hombre	18-jul-1959	17	Directivo	\$68.750	\$27.510	89	38	No
	130	Hombre	6-sep-1958	20	Directivo	\$59.375	\$30.000	89	6	No
	131	Hombre	8-feb-1962	15	Administrativo	\$31.500	\$15.750	89	22	No
	132	Hombre	17-may-1953	12	Administrativo	\$27.300	\$17.250	89	175	No
	133	Hombre	12-sep-1959	15	Administrativo	\$27.000	\$15.750	89	87	No

Ejemplo

Agrupar a los clientes según indicadores de frecuencia de compra, monto, cuotas impagas, frecuencia de atrasos, etc. en segmentos de comportamientos homogéneos

Clientes Buenos



78%
de la facturación

Casados, con hijos,
trabajadores autónomos
con ingreso superior a \$3000

Clientes Medios



20%
de la facturación

Ingresos regulares

Clientes Malos



2%
de la facturación

Ingresos bajos,
múltiples atrasos

Resultado: 3 agrupamientos.

Se reconocen los cluster en Clientes Buenos, Clientes Medios, y Clientes Malos.

Por ejemplo, el 78% de la facturación se concentra en el Cluster considerado de Clientes Buenos.

Los Clientes Buenos son casados, con hijos, trabajadores autónomos con ingreso superior a \$3000 pesos.

Medidas de Similitud

Distancia de Minkowski

$$d_r(x, y) = \left(\sum_{j=1}^J |x_j - y_j|^r \right)^{\frac{1}{r}}, \quad r \geq 1$$

- Distancia de Manhattan (r=1)


$$d_1(x, y) = \sum_{j=1}^J |x_j - y_j|$$

- Distancia Euclideana (r=2):

$$d_2(x, y) = \sqrt{\sum_{j=1}^J (x_j - y_j)^2}$$

- Distancia de Chebyshev (r→∞)


$$d_{\infty}(x, y) = \max_{j=1..J} |x_j - y_j|$$



Agrupamiento


K-Means (K-Medias)

- Divide los datos en k grupos, donde k es un número predefinido por el usuario.
- Asigna cada punto de datos al clúster cuyo centroide (media) es el más cercano.
- Es eficiente para grandes conjuntos de datos, pero sensible a los valores atípicos y a la elección inicial de los centroides.




Agrupamiento Jerárquico

- Crea una jerarquía de clústeres, representada como un dendrograma.
- No requiere especificar el número de clústeres por adelantado.
- Es útil para visualizar relaciones jerárquicas entre los datos.



3. DBSCAN (Density-Based Spatial Clustering of Applications with Noise)



- Agrupa puntos de datos basados en su densidad.
- Puede identificar clústeres de formas arbitrarias y es resistente a los valores atípicos.
- Requiere dos parámetros: radio de vecindad y número mínimo de puntos en la vecindad.




k-Media

- Agrupamiento particional
- Cada cluster está asociado con un centroide (valor de la media del cluster)
- Cada punto es asignado al cluster más cercano al centroide
- El número de clusters “K” debe ser especificado
- Es un algoritmo goloso
- Medida del error a minimizar







$$SSE = \sum_{i=1}^K \sum_{x \in C_i} d^2(m_i, x)$$




Coeficiente de Silhouette
(Típicamente entre 0 y 1)
Es mejor si es más cercano a 1)



Idea del algoritmo k-Media



Cluster Jerárquico




Traditional Dendrogram

- Forma de "árbol" o dendrograma
- No requiere un número predefinido de clústeres
- Es útil para explorar los datos a diferentes niveles de granularidad.
- Se recomienda su uso por el dendrograma que permite ver qué tan similares son dos grupos y en qué punto se fusionan, por ello tiene sentido con pocos datos.
- Es un algoritmo goloso

Idea del algoritmo de Cluster Jerárquico

Situación inicial




	p1	p2	p3	p4	p5	...
p1						
p2						
p3						
p4						
p5						
.						
.						
.						

Proximity Matrix

    ...    
 p1 p2 p3 p4 ... p9 p10 p11 p12


Situación intermedia

Después de algunos pasos, ya se tienen algunos cluster y se observa que C2 y C5 están más “cercanos”.




	C1	C2	C3	C4	C5
C1					
C2					
C3					
C4					
C5					

Proximity Matrix




Situación intermedia

¿Como se modifica la matriz de proximidad?




		C2 U C5	C3	C4
C1		?		
C2 U C5	?	?	?	?
C3		?		
C4		?		

Proximity Matrix



Como definir la similitud entre clusters




Otros métodos dirigidos por una función objetivo global:

- Criterio basado en min la variación de la función objetivo.
- El método de Ward fusiona los clústeres que minimizan el aumento total de la varianza intraclúster, buscando grupos compactos y esféricos.

DBSCAN



Original Points



Clusters

Resistente al ruido


Puede manejar clusters de diferentes tamaños y formas

Idea del algoritmo DBSCAN

Establecer:





Puntos
centrales, de
borde y de
ruido

Parámetros
Eps y MinPts




Como elegir el clustering adecuado?


k-Media




DBScan



Original Points



(MinPts=4, Eps=9.75).




(MinPts=4, Eps=9.92)

Selección del número óptimo de Clusters

El **método del codo** utiliza la distancia media de las observaciones a su centroide.


Es decir, se fija en las distancias intra-cluster. Cuanto **más grande** es el número de clusters **k**, la **varianza intra-cluster tiende a disminuir**. Cuanto menor es la distancia intra-cluster es mejor, ya que significa que los clústers son más compactos. El método del codo busca el valor k que satisfaga que un incremento de k, no mejore sustancialmente la distancia media intra-cluster.



Otra forma es con
el Coeficiente
Silhouette máximo

Selección del número óptimo de Clusters

SSE (“Sum of Squared Error”)



Determinación de k=10

LABORATORIO 1 – Data science

**Duración aprox:
30 Minutos**

Ejercicio:

1. Use el archivo `creditcardcsvpresent.csv`
2. Instale la aplicación de ciencia de datos gratuito **Weka** y realice agrupamientos k-media, jerárquicos y de densidad con DBScan, y compare los cluster con las clases. Intente conseguir el agrupamiento más similar a la clase.
3. Use la IA para generar un programa Python que realice lo mismo, pero selecciones el Índice de Rand Ajustado (ARI), para seleccionar el modelo que más se ajusta a la clase.

El Índice de Rand Ajustado

- Un valor de **1** en el ARI significa que el *clustering* y la clasificación real son idénticos (la correspondencia es perfecta).
- Un valor de **0** en el ARI indica que la similitud entre el *clustering* y la clasificación es la misma que la que se obtendría por casualidad.
- Un valor **negativo** en el ARI indica que el acuerdo es peor de lo que se esperaría por azar.

LABORATORIO 1 - Otros

**Duración aprox:
30 Minutos**

Ejercicio:

1. Use el archivo Iris.arff o bank.arff

age	age of customer in years (numeric)
sex	MALE / FEMALE
region	inner_city/rural/suburban/town
income	income of customer (numeric)
married	is the customer married (YES/NO)
children	number of children (numeric)
car	does the customer own a car (YES/NO)
save_acct	does the customer have a saving account (YES/NO)
current_acct	does the customer have a current account (YES/NO)
mortgage	does the customer have a mortgage (YES/NO)
pep	did the customer buy a PEP (Personal Equity Plan) after the last mailing (YES/NO)

2. ¡Cargue los datos en Excel e intente hacer grupos de clientes similares!.
3. Instale la aplicación de ciencia de datos gratuito **Weka o Knime** y realice agrupamientos, con varios tipos de agrupamientos.
4. Use la IA para programar el algoritmo K-means en Python, con el método del codo seleccione k, analice la salida y describa cada uno de los grupos mediante su centroide.

Solución:

<https://colab.research.google.com/drive/1EmsUTAoBjtjjwNGtfKui4460x0VgZGuj?usp=sharing>



Clasificación y Estimación

Es el proceso de organizar datos en grupos o categorías

Ejemplos:

Basado en la historia de cómo se han clasificado a los clientes.


Clasificar un “**nuevo**” cliente de acuerdo a su perfil sociodemográfico como un cliente Bueno, Medio, Malo.

Un clasificador de reconocimiento de imágenes puede etiquetar una imagen como "automóvil", "camión" o "persona".


Machine Learning

¿Qué es el machine Learning?

Traditional Programming



Machine Learning



Requiere entrenamiento!

Machine Learning

Ejemplo, determinar si un número es 2.

0 0 0 1 1 1 1 1 1 2

2 2 2 2 2 2 2 3 3 3

3 4 4 4 4 4 5 5 5 5

6 6 7 7 7 7 8 8 8 8

9 9 9 9 9 9 9 9 9 9

Machine Learning

Se prepara un gran volumen de datos de entrenamiento

label = 5



label = 0



label = 4



label = 1



label = 9



label = 2




label = 1



label = 3



label = 1



label = 4



label = 3



label = 5



label = 3



label = 6



label = 1




Machine Learning

Se construye un modelo


0 0 0 0 0 0 0 0 0 0 0 0 0 0
1 1 1 1 1 1 1 1 1 1 1 1 1 1
2 2 2 2 2 2 2 2 2 2 2 2 2 2
3 3 3 3 3 3 3 3 3 3 3 3 3 3
4 4 4 4 4 4 4 4 4 4 4 4 4 4
5 5 5 5 5 5 5 5 5 5 5 5 5 5
6 6 6 6 6 6 6 6 6 6 6 6 6 6
7 7 7 7 7 7 7 7 7 7 7 7 7 7
8 8 8 8 8 8 8 8 8 8 8 8 8 8
9 9 9 9 9 9 9 9 9 9 9 9 9 9

Data & Labels




0
1
2
3
4
5
6
7
8
9

El modelo de clasificación



Ejemplo de un modelo

Árboles de decisión



tree_titanic_survivors

Sibsp (Hermanos / Cónyuges)

Principales técnicas de clasificación

Logistic Regression




k Nearest Neighbor (kNN)



Support Vector Machine (SVM)



Neural Network




Naïve Bayes




Discriminant Analysis



Decision Tree



Bagged and Boosted Decision Trees



Common
Classification
Algorithms

Evaluación del modelo

La evaluación del rendimiento de un modelo de clasificación se basa en los recuentos de registros de test/prueba correctamente e incorrectamente pronosticados por el modelo.

Estos conteos se tabulan en una tabla conocida como **matriz de confusión**.

VALORES PREDICCIÓN	VALORES REALES	
	Positivo	Negativo
Positivo	Verdaderos positivos	Falsos Positivos
Negativo	Falsos Negativos	Verdaderos Negativos

Evaluación del modelo

Ejemplo

Fábula de Esopo: El niño que gritó lobo (*comprimido*)

Un joven pastor se aburre de cuidar el rebaño del pueblo. Para divertirse, grita, "¡Lobo!", a pesar de que no hay un lobo a la vista. Los vecinos corren para proteger el rebaño, pero se enojan mucho cuando se dan cuenta de que el niño les estaba bromeando.

[Repite el párrafo anterior N veces].

Una noche, el joven pastor ve un lobo real acercándose al rebaño y grita: "¡Lobo!". Los vecinos se niegan a ser engañados otra vez y se quedan en sus casas. El hambriento lobo convierte el rebaño en cortes de cordero. El pueblo está hambriento. Se produce un pánico.

Evaluación del modelo

Ejemplo

Hagamos las siguientes definiciones:

- "Lobo" es una **clase positiva**.
- Ningún lobo es una **clase negativa**.

Podemos resumir nuestro modelo de "predicción de lobos" con una matriz de confusión de 2 x 2 que muestra los cuatro resultados posibles:

Verdadero positivo (VP):

- Realidad: Un lobo amenazado.
- El pastor dijo: "Lobo".
- Resultado: El pastor es un héroe.

Falso positivo (FP):

- Realidad: Ningún lobo está amenazado.
- El pastor dijo: "Lobo".
- Resultado: Los vecinos están enojados con el pastor por despertarlos.

Falso negativo (FN):

- Realidad: Un lobo amenazado.
- El pastor dijo: "No hay un lobo".
- Resultado: El lobo se comió todas las ovejas.

Verdadero negativo (VN):

- Realidad: Ningún lobo está amenazado.
- El pastor dijo: "No hay un lobo".
- Resultado: Todos están bien.

Evaluación del modelo

Aunque una **matriz de confusión** proporciona la información necesaria para determinar qué tan bien funciona un modelo de clasificación, resumir esta información con un solo número haría más conveniente comparar el rendimiento de diferentes modelos.

=> Usar una métrica de rendimiento como la **Exactitud (Accuracy)**:

$$\text{exactitud} = \frac{VP + VN}{VP + FP + FN + VN}$$

VALORES PREDICCIÓN	Verdaderos positivos	Falsos Positivos
	Falsos Negativos	Verdaderos Negativos
VALORES REALES		

Evaluación del modelo

Intentemos calcular la precisión del siguiente modelo, que clasificó **100 tumores como maligos (la clase positiva) o benignos (la clase negativa)**:

Verdadero positivo (VP):

- Realidad: Maligno
- Predicción del modelo de AA: Maligno
- Cantidad de resultados de VP: 1

Falso positivo (FP):

- Realidad: Benigno
- Predicción del modelo de AA: Maligno
- Cantidad de resultados de FP: 1

Falso negativo (FN):

- Realidad: Maligno
- Predicción del modelo de AA: Benigno
- Número de resultados de FN: 8

Verdadero negativo (VN):

- Realidad: Benigno
- Predicción del modelo de AA: Benigno
- Cantidad de resultados de VN: 90

$$\text{exactitud} = \frac{VP + VN}{VP + FP + FN + VN} = \frac{1 + 90}{1 + 90 + 1 + 8} = 0.91$$

La exactitud llega a 0.91 o 91% (91 predicciones correctas de un total de 100 ejemplos).
Pregunta. ¿El clasificador de tumores está haciendo un buen trabajo en la identificación de malignidades?

Evaluación del modelo

Intentemos
como mal

Aunque la precisión del 91% puede parecer buena a primera vista, otro modelo de clasificación de tumores que siempre predice benigno lograría la misma exactitud (91/100 predicciones correctas) en nuestros ejemplos.

o, que clasificó **100 tumores** (se negativa):

o positivo (FP):

Realidad: Benigno

Predicción del modelo de AA: Maligno

Cantidad de resultados de FP: 1

o negativo (VN):

Realidad: Benigno

Cantidad de resultados de VN: 90

$$\text{exactitud} = \frac{VP + VN}{VP + FP + FN + VN} = \frac{1 + 90}{1 + 90 + 1 + 8} = 0.91$$

La exactitud llega a 0.91 o 91% (91 predicciones correctas de un total de 100 ejemplos).
Pregunta. ¿El clasificador de tumores está haciendo un buen trabajo en la identificación de malignidades?



Evaluación del modelo

La **precisión** intenta responder a la siguiente pregunta: ¿Qué proporción de identificaciones **positivas** fue correcta?

$$\text{precisión} = \frac{VP}{VP + FP}$$

Verdaderos positivos (VP): 1	Falsos positivos (FP): 1
Falsos negativos (FN): 8	Verdaderos negativos (VN): 90

$$\text{precisión} = \frac{VP}{VP + FP} = \frac{1}{1 + 1} = 0.5$$

Nuestro modelo tiene una precisión de 0.5, es decir, cuando predice que un tumor es maligno, es correcto el 50% de las veces.

Evaluación del modelo

La **recuperación** intenta responder a la siguiente pregunta: ¿Qué proporción de **positivos reales** se identificó en forma correcta?

$$\text{Recall} = \frac{VP}{VP + FN}$$


Verdaderos positivos (VP): 1	Falsos positivos (FP): 1
Falsos negativos (FN): 8	Verdaderos negativos (VN): 90

$$\text{Recall} = \frac{VP}{VP + FN} = \frac{1}{1 + 8} = 0.11$$

Nuestro modelo tiene una recuperación de 0.11; en otras palabras, identifica correctamente el 11% de los tumores malignos.

¿Que es la curva ROC?

Para la elección entre dos pruebas diagnósticas distintas, se recurre a las curvas ROC, ya que es una medida global e independiente del punto de corte.



Sensibilidad = Recall =
 $VP / (VP + FN)$

Especificidad =
 $VN / (VN + FP)$

1-Especificidad =
 $FP / (VN + FP) = FPR$


Cada curva es un clasificador y cada punto es dado por un umbral distinto para él.

¿Que es el AUC?

Es el área bajo la curva ROC


AUC=1

+ valor diagnóstico perfecto




AUC=0,8

+ valor diagnóstico



AUC=0,5

+ sin valor diagnóstico



A modo de guía para interpretar las curvas ROC se han establecido los siguientes intervalos para los valores de AUC:

[0.5]: Es como lanzar una moneda.

[0.5, 0.6): Test malo.

[0.6, 0.75): Test regular.

[0.75, 0.9): Test bueno.

[0.9, 0.97): Test muy bueno.

[0.97, 1): Test excelente.


El problema del sobreaprendizaje

Cuanto mayor sea su complejidad, los modelos de clasificación tienden a ajustarse más al conjunto de entrenamiento utilizado en su construcción (sobreaprendizaje), lo que los hace menos útiles para clasificar nuevos datos.



- El conjunto de entrenamiento contiene patrones útiles, pero también ruido y no es conveniente adaptarse demasiado a ellos.
- El conjunto de prueba debe ser “ojalá” independiente del conjunto de entrenamiento.

El problema del sobreaprendizaje

Regression:






predictor too inflexible:
cannot capture pattern



predictor too flexible:
fits noise in the data


Classification:



El problema del sobreaprendizaje

¿Como Disminuirlo?

Acá detener



Training Set

Tid	Attrib1	Attrib2	Attrib3	Class
1	Yes	Large	125K	No
2	No	Medium	100K	No
3	No	Small	70K	No
4	Yes	Medium	120K	No
5	No	Large	95K	Yes
6	No	Medium	60K	No
7	Yes	Large	220K	No
8	No	Small	85K	Yes
9	No	Medium	75K	No
10	No	Small	90K	Yes

Test Set

Tid	Attrib1	Attrib2	Attrib3	Class
11	No	Small	55K	?
12	Yes	Medium	80K	?
13	Yes	Large	110K	?
14	No	Small	95K	?
15	No	Large	67K	?

LABORATORIO 2 – Data science

Duración aprox:
30 Minutos

Ejercicio:

1. Use el archivo, adult.arff
2. Use la IA y programe en Python un clasificador que supere el 95% para AUC o bien para F1_score. Solicite a la IA recomendaciones para mejorar el modelo y aplíquelas.

El F1-Score es especialmente útil para **conjuntos de datos desequilibrados**, donde la clase minoritaria es de gran interés (por ejemplo, en la detección de fraudes o enfermedades raras). La precisión simple puede ser engañosa en estos casos.

LABORATORIO 2 - Otros

Duración aprox:
30 Minutos

Ejercicio: 1. Use el archivo, adult.arff

```
@attribute age numeric
@attribute workclass { Private, Self-emp-not-inc, Self-emp-inc, Federal-gov, Local-gov, State-gov, Without-pay, Never-worked }
@attribute fnlwgt numeric
@attribute education { Bachelors, Some-college, 11th, HS-grad, Prof-school, Assoc-acdm, Assoc-voc, 9th, 7th-8th, 12th, Masters, 1st-4th, 1
@attribute education-num numeric
@attribute marital-status { Married-civ-spouse, Divorced, Never-married, Separated, Widowed, Married-spouse-absent, Married-AF-spouse }
@attribute occupation { Tech-support, Craft-repair, Other-service, Sales, Exec-managerial, Prof-specialty, Handlers-cleaners, Machine-op-i
moving, Priv-house-serv, Protective-serv, Armed-Forces }
@attribute relationship { Wife, Own-child, Husband, Not-in-family, Other-relative, Unmarried }
@attribute race { White, Asian-Pac-Islander, Amer-Indian-Eskimo, Other, Black }
@attribute sex { Female, Male }
@attribute capital-gain numeric
@attribute capital-loss numeric
@attribute hours-per-week numeric
@attribute native-country { United-States, Cambodia, England, Puerto-Rico, Canada, Germany, Outlying-US(Guam-USVI-etc), India, Japan, Gree
Philippines, Italy, Poland, Jamaica, Vietnam, Mexico, Portugal, Ireland, France, Dominican-Republic, Laos, Ecuador, Taiwan, Haiti, Columbi
Thailand, Yugoslavia, El-Salvador, Trinidad&Tobago, Peru, Hong, Holand-Netherlands }
@attribute class { >50K, <=50K }
```



2. Utilice **Weka** o **Knime** y realice clasificaciones con diferentes métodos para determinar que modelo clasifica mejor los datos de testeo. ¿¿Cuál fue el mejor?.
3. Use la IA y programe en Python el árbol de decisión, analice los principales indicadores del modelo.

Solución: <https://colab.research.google.com/drive/1z8b1yFnQs26GR9-4q3JAoeHMuzqOFXj8?usp=sharing>

LABORATORIO 2 - Otros

Solución

Seleccione el algoritmo j48 (arbol de decision), revise los valores por defecto de la ejecución.



Validación
cruzada para
X Folds


Divide los datos
en
entrenamiento
y test

LABORATORIO 2 - Otros

Solución

¿Que es la validación cruzada?

Esquema k-fold con k=4 y un solo clasificador



LABORATORIO 2 - Otros

¿Cuales son los principales parámetros?

La reducción de errores de poda es un método posterior a la poda que utiliza un conjunto de retención (una fracción de los datos de entrenamiento) para tomar decisiones de poda. Comenzando en las hojas, cada nodo se reemplaza con su clase más popular. Si la precisión de la predicción no se ve afectada, el cambio se mantiene.

Parameter	Value
batchSize	100
binarySplits	False
collapseTree	True
confidenceFactor	0.25
debug	False
doNotCheckCapabilities	False
doNotMakeSplitPointActualValue	False
minNumObj	2
numDecimalPlaces	2
numFolds	3
reducedErrorPruning	False
saveInstanceData	False
seed	1
subtreeRaising	True
unpruned	False
useLaplace	False
useMDLcorrection	True

Árbol binario o no

Tasa asociada al sobreaprendizaje. Un valor más bajo genera un árbol más pequeño pero baja % de aciertos.

Cantidad Min de registros en las hojas

¿Se permite realizar podas?

Resultados, parte 1

=== Run information ===

```
Scheme:      weka.classifiers.trees.J48 -C 0.25 -M 2
Relation:     adult
Instances:    48842
Attributes:   15
              age
              workclass
              fnlwgt
              education
              education-num
              marital-status
              occupation
              relationship
              race
              sex
              capital-gain
              capital-loss
              hours-per-week
              native-country
              class
Test mode:    split 66.0% train, remainder test
```

=== Classifier model (full training set) ===

LABORATORIO 2 - Otros

Resultados, parte 2

J48 pruned tree

```

capital-gain <= 6849
|   marital-status = Married-civ-spouse
|   |   capital-loss <= 1844
|   |   |   education-num <= 11
|   |   |   |   capital-gain <= 5060
|   |   |   |   |   age <= 29: <=50K (1999.0/241.0)
|   |   |   |   |   age > 29
|   |   |   |   |   |   hours-per-week <= 34: <=50K (1243.0/155.0)
|   |   |   |   |   |   hours-per-week > 34
|   |   |   |   |   |   |   education-num <= 9: <=50K (6969.0/1820.0)
|   |   |   |   |   |   |   education-num > 9
|   |   |   |   |   |   |   |   capital-loss <= 1510
|   |   |   |   |   |   |   |   |   occupation = Tech-support
|   |   |   |   |   |   |   |   |   |   capital-gain <= 3103: >50K (169.69/71.36)
|   |   |   |   |   |   |   |   |   |   capital-gain > 3103: <=50K (12.05/2.0)

```

Cuantos coinciden
con la clase y cuantos
no, en la hoja

...

...

...

...

Number of Leaves : 696

Size of the tree : 911

Time taken to build model: 2.59 seconds

LABORATORIO 2 - Otros

Resultados, parte 3

La estadística kappa mide la certeza de predicción con la clase verdadera: 1.0 significa acuerdo completo, cercano a 0 o menor indica mucha diferencia entre test y lo esperado.

=== Evaluation on test split ===

Time taken to test model on test split: 0.1 seconds

=== Summary ===

Correctly Classified Instances	14362	86.4868 %
Incorrectly Classified Instances	2244	13.5132 %
Kappa statistic	0.5924	
Mean absolute error	0.1911	
Root mean squared error	0.3158	
Relative absolute error	52.6936 %	
Root relative squared error	74.6356 %	
Total Number of Instances	16606	

$$\frac{|p_1 - a_1| + \dots + |p_n - a_n|}{n}$$

$$\sqrt{\frac{(p_1 - a_1)^2 + \dots + (p_n - a_n)^2}{n}}$$

LABORATORIO 2 - Otros

Resultados, parte 4

=== Detailed Accuracy By Class ===



	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0.604	0.056	0.768	0.604	0.676	0.599	0.896	0.762	>50K
	0.944	0.396	0.887	0.944	0.915	0.599	0.896	0.957	<=50K
Weighted Avg.	0.865	0.316	0.859	0.865	0.859	0.599	0.896	0.912	

=== Confusion Matrix ===

a	b	<-- classified as
2344	1534	a = >50K
710	12018	b = <=50K

LABORATORIO 2 - Otros

Visualizar el árbol



Botón derecho de mouse sobre el modelo de la lista de resultados y elegir opción "Auto Scale"



Asociación

La minería de reglas de asociación se utiliza cuando se desea encontrar una asociación entre diferentes objetos en un conjunto.

Ejemplos:

- Encontrar las reglas que determinan la interrelación entre productos para clientes online de un banco. “Cuando un cliente se activa en Caja de Ahorros, el siguiente producto donde se activa es Préstamos Personales. Este patrón ocurre el 65 % de los casos.”
- “En un supermercado cuando un cliente compra pañales y compra cerveza, es muy probable que compre papas fritas.”

Conceptos clave:

Ítems: Son los elementos individuales que se analizan. Por ejemplo, en un supermercado, los ítems podrían ser productos como "leche", "pan" o "huevos".

Transacciones: Son conjuntos de ítems que ocurren juntos. Por ejemplo, una transacción podría ser la lista de productos que un cliente compra en una sola visita al supermercado.

Reglas de asociación: Son expresiones de la forma "Si A, entonces B", donde A y B son conjuntos de ítems. Estas reglas indican que la presencia de los ítems en A tiende a implicar la presencia de los ítems en B.

Entonces, esta técnica nace para encontrar reglas entre las transacciones.

Transacciones

TID	Artículos
1	Pan, leche, huevos
2	Pan, pañales, cerveza
3	Leche, pañales, cerveza
4	Pan, leche, pañales, cerveza
5	Pan, leche, huevos, cerveza

Reglas de asociación

{pañales} → {cerveza}

{leche, pan} → {huevos}

{cerveza, pan} → {leche, huevos}

Métricas importantes:

Para evaluar la calidad de las reglas de asociación, se utilizan tres métricas principales:

Soporte: Mide la frecuencia con la que un conjunto de ítems aparece en el conjunto de datos. Un alto soporte indica que el patrón es común.

Confianza: Mide la probabilidad de que el ítem B aparezca en una transacción, dado que el ítem A ya está presente. Una alta confianza indica que la regla es confiable.

Lift: Mide qué tan probable es que el ítem B se compre con el ítem A, en comparación con la probabilidad de comprar el ítem B solo. Un lift mayor que 1 indica que los ítems están relacionados positivamente.

¿Se puede usar el método con un archivo de datos?

Si. Los campos los podemos transformar en reglas del tipo:
{Shop Online = Yes} → {Privacy Concerns = Yes}

Internet survey data with categorical attributes.

Gender	Level of Education	State	Computer at Home	Chat Online	Shop Online	Privacy Concerns
Female	Graduate	Illinois	Yes	Yes	Yes	Yes
Male	College	California	No	No	No	No
Male	Graduate	Michigan	Yes	Yes	Yes	Yes
Female	College	Virginia	No	No	Yes	Yes
Female	Graduate	California	Yes	No	No	Yes
Male	College	Minnesota	Yes	Yes	Yes	Yes
Male	College	Alaska	Yes	Yes	Yes	No
Male	High School	Oregon	Yes	No		
Female	Graduate	Texas	No	Yes		
...	...	...	...	...		



Codificación one-hot coding

Internet survey data after binarizing categorical and symmetric binary attributes.

Male	Female	Education = Graduate	Education = College	...	Privacy = Yes	Privacy = No
0	1	1	0	...	1	0
1	0	0	1	...	0	1
1	0	1	0	...	1	0
0	1	0	1	...	1	0
0	1	1	0	...	1	0
1	0	0	1	...	1	0

LABORATORIO 3

Duración aprox:
30 Minutos

Ejercicio:

1. Use el archivo, vote.arff (1984 United States Congressional Voting Records Database)

```
% Attribute Information:
% 1. Class Name: 2 (democrat, republican)
% 2. handicapped-infants: 2 (y,n)
% 3. water-project-cost-sharing: 2 (y,n)
% 4. adoption-of-the-budget-resolution: 2 (y,n)
% 5. physician-fee-freeze: 2 (y,n)
% 6. el-salvador-aid: 2 (y,n)
% 7. religious-groups-in-schools: 2 (y,n)
% 8. anti-satellite-test-ban: 2 (y,n)
% 9. aid-to-nicaraguan-contras: 2 (y,n)
% 10. mx-missile: 2 (y,n)
% 11. immigration: 2 (y,n)
% 12. synfuels-corporation-cutback: 2 (y,n)
% 13. education-spending: 2 (y,n)
% 14. superfund-right-to-sue: 2 (y,n)
% 15. crime: 2 (y,n)
% 16. duty-free-exports: 2 (y,n)
% 17. export-administration-act-south-africa: 2 (y,n)
```

2. Utilice **Weka** y obtenga las reglas de asociación que tengan al menos un soporte de un 0.5 y una confianza de 0.2. Explique las reglas.
3. Use la IA y programe el algoritmo apriori en Python y analice los principales indicadores del modelo.

Solución: https://colab.research.google.com/drive/1I8UPLmsdS-9vYrB8HfxmZN9_humgb1Ps?usp=sharing

Weka para reglas de asociación

Algoritmo

The screenshot displays the Weka GUI with the 'Associate' tab selected. The 'Associator' section shows 'Apriori' selected, with its command line parameters: `-N 10 -T 0 -C 0.9 -D 0.05 -U 1.0 -M 0.45 -S -1.0 -c -1`. The 'Associator output' pane shows the results of the execution, including the minimum support (0.45), minimum metric (confidence: 0.9), and the generated sets of large itemsets. The 'Result list' on the left shows two entries for 'Apriori'.

The 'weka.gui.GenericObjectEditor' window is open, showing the configuration for the 'weka.associations.Apriori' class. The 'About' section describes it as a class implementing an Apriori-type algorithm. The configuration parameters are as follows:

Parameter	Value
car	False
classIndex	-1
delta	0.05
doNotCheckCapabilities	False
lowerBoundMinSupport	0.45
metricType	Confidence
minMetric	0.9
numRules	10
outputItemSets	False
removeAllMissingCols	False

Parámetros

Weka para reglas de asociación

Resultados

Minimum support: 0.45 (196 instances)

Minimum metric <confidence>: 0.9

Best rules found:


1. adoption-of-the-budget-resolution=y physician-fee-freeze=n 219 ==> Class=democrat 219
<conf:(1)> lift:(1.63) lev:(0.19) [84] conv:(84.58)
2. adoption-of-the-budget-resolution=y physician-fee-freeze=n aid-to-nicaraguan-contras=y
198 ==> Class=democrat 198 <conf:(1)> lift:(1.63) lev:(0.18) [76] conv:(76.47)
3. physician-fee-freeze=n aid-to-nicaraguan-contras=y 211 ==> Class=democrat 210
<conf:(1)> lift:(1.62) lev:(0.19) [80] conv:(40.74)
4. physician-fee-freeze=n education-spending=n 202 ==> Class=democrat 201 <conf:(1)>
lift:(1.62) lev:(0.18) [77] conv:(39.01)
5. physician-fee-freeze=n 247 ==> Class=democrat 245 <conf:(0.99)> lift:(1.62) lev:(0.21)
[93] conv:(31.8)
6. el-salvador-aid=n Class=democrat 200 ==> aid-to-nicaraguan-contras=y 197 <conf:(0.98)>
lift:(1.77) lev:(0.2) [85] conv:(22.18)
7. el-salvador-aid=n 208 ==> aid-to-nicaraguan-contras=y 204 <conf:(0.98)> lift:(1.76)
lev:(0.2) [88] conv:(18.46)
8. adoption-of-the-budget-resolution=y aid-to-nicaraguan-contras=y Class=democrat 203 ==>
physician-fee-freeze=n 198 <conf:(0.98)> lift:(1.72) lev:(0.19) [82] conv:(14.62)
9. el-salvador-aid=n aid-to-nicaraguan-contras=y 204 ==> Class=democrat 197 <conf:(0.97)>
lift:(1.57) lev:(0.17) [71] conv:(9.85)
10. aid-to-nicaraguan-contras=y Class=democrat 218 ==> physician-fee-freeze=n 210
<conf:(0.96)> lift:(1.7) lev:(0.2) [86] conv:(10.47)

Interpolación (regresión)

Permite estimar valores desconocidos entre datos o puntos conocidos.

- Interpolación de Datos Meteorológicos
- Interpolación de Fenómenos físicos.
- Estimación del valor de un arriendo o venta de una casa.
- Estimación de la tasa de evaporación en una salmuera de litio.

Modelos son: Redes neuronales, Random Forest, M5P, La interpolación polinómica de Lagrange.



Interpolación (regresión)

Selección de variables: No todas las variables son útiles.

Multicolinealidad: Ocurre cuando dos o más variables predictoras están altamente correlacionadas entre sí.

Suposiciones del modelo: La mayoría de los modelos de regresión, como la regresión lineal, se basan en supuestos clave. Por ejemplo: la relación entre las variables debe ser lineal, los errores del modelo deben estar distribuidos normalmente, y la varianza de los errores debe ser constante (homocedasticidad). Violar estos supuestos puede llevar a conclusiones incorrectas.

Interpretación de los coeficientes: Es fundamental entender qué significan los coeficientes del modelo.

LABORATORIO 4

Duración aprox:
20 Minutos

Ejercicio: Uso de IA para determinar la Regresión para la formula de la Viscosidad de la salmuera de CaCl_2

1. Realice el trabajo de manera individual.
2. Descargue la aplicación Mepx <https://mepx.org/>
3. Cargue en la aplicación el archivo CaCl_2 .csv
4. Ejecute el programa con las instrucciones del docente e intente descubrir la ecuación a partir de los datos.
5. Cargue la fórmula obtenida en Excel y estime la medida **MAPE** (Mean Absolute Percentage Error) y R^2 .

Pronóstico

El análisis predictivo consiste en estudiar los datos históricos y actuales para hacer predicciones sobre el futuro.

Predecir el abandono de un cliente para una universidad.

Predecir el precio de un producto.

Predecir las ventas y/o gastos,

Algunas técnicas de pronóstico son Análisis de series temporales, regresiones, modelos econométricos, redes neuronales.



Pronóstico


Para determinar pronósticos a corto plazo, se pueden emplear los diferentes métodos de series de tiempo.

Una **serie de tiempo** es una recopilación cronológica e histórica de datos y a partir de estos se puede hacer una predicción del futuro de forma razonable.

Ejemplo: Tasa de desempleo mensual 2002 a 2014 en RM


La función de pronóstico sería de la forma

$$\begin{aligned}
 X_t = & a \\
 & + b_1 X_{t-1} \\
 & + \dots \\
 & + b_n X_{t-n} \\
 & + \text{error}
 \end{aligned}$$




Series de tiempo

Ejemplo de serie estacionaria




Pronóstico


Ejemplo series NO estacionarias




Stationary series



Non-Stationary series



Stationary series




Non-Stationary series


No es estacionaria,
su varianza se
incrementa

Media no es Cte

Ojo, Para poder lidiar con
este problema, podemos
transformar y convertir
series no estacionarias en
series estacionarias.



Stationary series



Non-Stationary series

la autocovarianza no es constante


Red recurrente

- En las redes neuronales regulares, la información circula desde la capa de entrada a la salida y no se almacena.
- Sin embargo, hay aplicaciones donde la entrada anterior aporta en el proceso de la entrada actual.
- Por ejemplo, en una aplicación de interprete de lenguaje, si detectamos la palabra «la», esta salida nos proporciona mucha información sobre la siguiente palabra que vamos a procesar ya que implica que muy probablemente sea un sustantivo, femenino, singular lo que venga a continuación.

Las redes neuronales recurrentes solucionan el problema que tienen las redes neuronales regulares permitiendo que se almacene un «estado» o memoria que nos permite ser usado para la entrada posterior.

Red recurrente

¿Que es una red recurrente?.




Para generar la salida tienen en cuenta no sólo lo que ocurre en el instante de tiempo actual sino la información proveniente de instantes de tiempo anteriores, lo que las hace ideales para analizar secuencias.

Las Redes Neuronales Recurrentes usan un cierto tipo de “memoria” para generar la salida deseada.

Red recurrente

La siguiente red genera un nombre dándole una letra.


No siempre genera el mismo, ya que depende de que tenga cargada la memoria.



Es importante aclarar que en la figura vemos 10 bloques, pero la Red Recurrente es una sola. La idea de mostrar múltiples bloques es simplemente mostrar qué entradas y salidas se obtienen en diferentes instantes de tiempo.

RED NEURONAL LSTM

La Long Short-Term Memory (LSTM), puede procesar datos secuencialmente y mantener su estado oculto a lo largo del tiempo. Es una red recurrente.



Para mayor detalle ver

<https://colah.github.io/posts/2015-08-Understanding-LSTMs/>

ACTIVIDAD PARA LA CASA

Tarea: Análisis de datos usando métodos de ciencia de datos

Objetivo: Aplicar algoritmos de agrupamiento, clasificación y asociación para extraer información desde datos ubicados en **UCI Machine Learning Repository**. El docente dará un listado con los datos posibles de usar. Puede usar la IA.

Actividades:

1. Grupos de 2 personas. Indique el link a los datos.
2. Utilizar algún algoritmo de agrupamiento: Justifique el número de cluster propuesto e interprete cada grupo.
3. Utilizar algoritmos de clasificación: Determinar que algoritmo tiene mejores predicciones con datos de testeo. Indique mejoras que podría realizar a futuro a sus datos o proceso para mejorar los indicadores. Para ello, asesórese con la IA!
4. Aplicar el algoritmo Apriori para descubrir reglas de asociación entre los datos. Explicar las 6 reglas con mejores indicadores para soporte y confianza. Explique el lift.
5. Suba al Blackboard, una ppt de máximo 10 páginas, que resuma el trabajo realizado para presentarlo en la próxima clase.



Clase 2 (9/Enero/2026 Viernes 16:30-21:45)

Planificación del curso


Clase 2 (9/Enero/2026 Viernes 16:30-21:45)

- Planificación del proyecto
- Recolección de la información
- Procesamiento de la información

Trabajo de Aplicación: Desarrollo de un experimento de Data science.


Planificación del proyecto

Data Science Lifecycle



Planificación del proyecto

CRISP-DM (Cross-Industry Standard Process for Data Mining) **es un modelo de proceso** estándar ampliamente utilizado en **proyectos de ciencia de datos en la industria**. Proporciona un marco estructurado para planificar y ejecutar proyectos, asegurando que se aborden todas las etapas necesarias para obtener resultados valiosos.



¿Qué es y para qué sirve?

- Es una **metodología** que define las fases de un proyecto de ciencia de datos, desde la comprensión del problema hasta la implementación de la solución.
- Su objetivo es garantizar que los proyectos de ciencia de datos se realicen de manera sistemática y eficiente, aumentando las posibilidades de éxito.
- Es flexible y adaptable a diferentes tipos de proyectos y sectores.

https://www.ibm.com/docs/es/SS3RA7_18.4.0/pdf/ModelerCRISPDM.pdf

Las 6 fases del método CRISP-DM:

1. Comprensión del negocio:

1. Se define el problema de negocio y se establecen los objetivos del proyecto.
2. Se identifican los requisitos y restricciones del proyecto.

2. Comprensión de los datos:

1. Se recopilan y exploran los datos disponibles.
2. Se evalúa la calidad de los datos y se identifican posibles problemas.

3. Preparación de los datos:

1. Se limpian y transforman los datos para que sean adecuados para el modelado.
2. Se seleccionan las variables relevantes y se crean nuevas variables si es necesario.

4. Modelado:

1. Se seleccionan y aplican técnicas de modelado para generar modelos predictivos o descriptivos.
2. Se evalúa el rendimiento de los modelos.

5. Evaluación:

1. Se evalúan los resultados del modelo en función de los objetivos del negocio.
2. Se determina si el modelo cumple con los requisitos del proyecto.

6. Despliegue:

1. Se implementa el modelo en el entorno de producción.
2. Se realiza un seguimiento del rendimiento del modelo y se realizan ajustes si es necesario.

LABORATORIO 5

Duración aprox:
15 Minutos

Ejercicio:

1. Tomémonos 5 minutos para analizar la documentación de CRISP-DM
2. Con relación a la sección **Comprensión del negocio**, ¿Estima que le da alguna guía interesante para el taller que realizó para la casa o para algún proyecto en su empresa?.
3. Con relación a la sección **Comprensión de los datos**, ¿Estima que le podrá servir para lo que se verá hoy en este curso?.

Su opinión es importante para la clase!.



UNIVERSIDAD
SAN SEBASTIAN
VOCACIÓN POR LA EXCELENCIA



Recolección de la información

Recolección de la información

1. Definición de objetivos y necesidades de datos:

- Identificación de preguntas clave
- Definición de variables relevantes
- Determinación de la granularidad de los datos

2. Fuentes de datos:

- Bases de datos internas
- Fuentes externas (Sensores y dispositivos IoT, APIs, Web scraping, Encuestas y cuestionarios)
- EDA (Análisis Exploratorio de Datos)

3. Consideraciones éticas y legales:

- Privacidad de los datos
- Consentimiento informado
- Sesgos y discriminación

4. Calidad de los datos: EDA (Análisis Exploratorio de Datos)

- Exactitud
- Integridad
- Consistencia de los datos.

Inspección de los datos

EDA (Análisis Exploratorio de Datos)

El EDA se basa en la inspección de datos para obtener una comprensión inicial de los datos.

El EDA va más allá de la simple inspección de datos, ya que también implica generar hipótesis y descubrir patrones ocultos.

Las técnicas de inspección de datos, como la visualización y el cálculo de estadísticas descriptivas, son herramientas esenciales en el arsenal del EDA.

Ejemplo de Inspección de los datos

Datos '<https://raw.githubusercontent.com/plotly/datasets/master/diabetes.csv>'

```
print(df.head())
```

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
0	6	148	72	35	0	33.6	0.627	50	1
1	1	85	66	29	0	26.6	0.351	31	0
2	8	183	64	0	0	23.3	0.672	32	1
3	1	89	66	23	94	28.1	0.167	21	0
4	0	137	40	35	168	43.1	2.288	33	1

```
print(df.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 768 entries, 0 to 767
Data columns (total 9 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Pregnancies                          768 non-null    int64
1   Glucose                              768 non-null    int64
2   BloodPressure                        768 non-null    int64
3   SkinThickness                        768 non-null    int64
4   Insulin                              768 non-null    int64
5   BMI                                  768 non-null    float64
6   DiabetesPedigreeFunction             768 non-null    float64
7   Age                                  768 non-null    int64
8   Outcome                              768 non-null    int64
dtypes: float64(2), int64(7)
memory usage: 54.1 KB
None
```



```
print(df.describe())
```

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin
count	768.000000	768.000000	768.000000	768.000000	768.000000
mean	3.845052	120.894531	69.105469	20.536458	79.799479
std	3.369578	31.972618	19.355807	15.952218	115.244002
min	0.000000	0.000000	0.000000	0.000000	0.000000
25%	1.000000	99.000000	62.000000	0.000000	0.000000
50%	3.000000	117.000000	72.000000	23.000000	30.500000
75%	6.000000	140.250000	80.000000	32.000000	127.250000
max	17.000000	199.000000	122.000000	99.000000	846.000000

	BMI	DiabetesPedigreeFunction	Age	Outcome
count	768.000000	768.000000	768.000000	768.000000
mean	31.992578	0.471876	33.240885	0.348958
std	7.884160	0.331329	11.760232	0.476951
min	0.000000	0.078000	21.000000	0.000000
25%	27.300000	0.243750	24.000000	0.000000
50%	32.000000	0.372500	29.000000	0.000000
75%	36.600000	0.626250	41.000000	1.000000
max	67.100000	2.420000	81.000000	1.000000

Histogramas

- Usualmente muestra la distribución de valores de una sola variable.
- Divide los valores en BINs y muestre un diagrama de barras del número de objetos en para BINs.
- La altura de cada barra indica el número de objetos.
- La forma del histograma depende de la cantidad de BINs




Técnicas de visualización

Box Plots

Para **calcular un percentil**, primero se ordena el conjunto de datos de menor a mayor. Luego, se calcula la posición del percentil deseado multiplicando el percentil por la cantidad total de datos y dividiendo por


$$\text{Posición} = \lceil \text{Percentil} * n / 100 \rceil$$

Finalmente, se identifica el valor en esa posición del conjunto de datos ordenado.



Técnicas de visualización

Box Plots se puede utilizar para comparar atributos.



Calidad de los datos

La mala calidad de los datos afecta negativamente a muchos esfuerzos de procesamiento de datos.

¿Qué tipo de problemas de calidad de datos existen?

¿Cómo podemos detectar problemas con los datos?


¿Qué podemos hacer con estos problemas?

Ejemplo en ciencia de datos:

Un modelo de clasificación para detectar personas que están en evaluación de riesgo de préstamo que se construye utilizando datos deficientes

=> A algunos candidatos dignos de crédito se les niegan los préstamos.

=> Se otorgan más préstamos a las personas que incumplen.



Calidad de los datos

Algunos ejemplos de problemas de calidad de datos:

- Ruido y valores atípicos.
- Valores faltantes
- Datos duplicados




Ruido


Para los objetos, el ruido es un objeto extraño.

Para los atributos, el ruido se refiere a la modificación de los valores originales.

Ejemplo: distorsión de la voz de una persona al hablar por un teléfono defectuoso.




Ondas sinusoidales



Ondas sinusoidales + ruido

Ruido



El ruido no siempre es malo

- Regularización en el aprendizaje automático: En ciertos casos, añadir ruido controlado a los datos de entrenamiento puede actuar como una forma de regularización, lo que ayuda a prevenir el sobreajuste y mejora la capacidad de generalización de los modelos.
- Privacidad diferencial: En el análisis de datos sensibles, se puede añadir ruido intencional para proteger la privacidad de los individuos.
- Pruebas de robustez: En el desarrollo de software, introducir ruido en los datos de prueba puede ayudar a identificar posibles fallos y mejorar la robustez de los sistemas.
- Estimulación en el aprendizaje: Tal como ocurre con los humanos, en el aprendizaje automático, exponer a los algoritmos a datos con cierto grado de ruido, puede ayudar a que estos algoritmos sean mas resilientes a los datos del mundo real, que casi siempre contienen cierto grado de imperfecciones.


Los valores atípicos

Los valores atípicos son objetos de datos con características que son considerablemente diferentes a la mayoría de los otros objetos de datos en el conjunto de datos

Caso 1: los valores atípicos son ruidos que interfieren con el análisis de datos

Caso 2: Los valores atípicos son el objetivo de nuestro análisis.

Fraude de tarjeta de crédito
Detección de intrusión




Enfoque estadísticos para valores atípicos

Supongamos un modelo paramétrico que describe la distribución de los datos (por ejemplo, la distribución normal)


Aplicar una prueba estadística

- Parámetro de distribución (por ejemplo, media, varianza)

- Puntuación Z (Z-score): Mide cuántas desviaciones estándar se aleja un valor de la media.



- Rango Intercuartílico (IQR): Es menos sensible a valores extremos o atípicos que otras medidas de dispersión



Valores faltantes

Razones de los valores faltantes:

- La información no se recopila (por ejemplo, las personas se niegan a dar su edad y peso)
- Es posible que los atributos no sean aplicables a todos los casos (por ejemplo, el ingreso anual no es aplicable a los niños)

Manejo de valores faltantes

- Eliminar objetos de datos o variables
- Estimar valores perdidos
 - Ejemplo: resultados del censo
- Ignorar el valor perdido durante el análisis

Ejemplos de datos perdidos o faltantes

Edad	Género	Peso	Estatura	Servicio de salud	Enfermedades previas	Vacunas
5	F	38		1	1	1
6	M	39	113	2	2	1
13	M	38	131	2		
7	F	43	119	1	1	2
5	M	42	118	1	2	1
9	M					
6	M	49	140	1	2	1
	F	33	111	1	2	2
6	F	20	119	1	2	2
9	M	38	133		1	1
9	F		136	1	2	1
4	F	24	106	1	2	
6	M	48	100	1	1	2
5	M	28	112	1	1	1
8	M	21	111	2	2	1
4						
8	F	38	119	2	2	2
4	M		125	2	1	1
4	M	25	140	2	1	2
8	F	50	132	1		1
5				2	1	2
11		29	121	1	2	
12	F	45	118	2	2	1
4	F	28		2	2	1
8	M	40	127		1	2

Valores faltantes

Falta completamente al azar (MCAR)

- La falta de un valor es independiente de los atributos. Ejemplo una encuesta, no había nadie en la casa.
- El análisis puede ser imparcial en general

Falta al azar (MAR)

- La falta del dato está relacionada con otras variables, por ejemplo: si es niño no tiene N° celular.
- Rellene valores basados en otros valores
- Casi siempre se produce un sesgo en el análisis.

No falta al azar (MNAR)

- La falta del dato está relacionada con mediciones no observadas.
- Falta informativa o no ignorable.
- No es posible conocer la situación a partir de los datos.

Valores duplicados

El conjunto de datos puede incluir objetos de datos que son duplicados, o casi duplicados entre sí

Problema importante al combinar datos de fuentes heterogéneas


Ejemplos:

La misma persona con múltiples direcciones de correo electrónico

Limpieza de datos

Proceso de tratar con problemas de datos duplicados

¿Siempre es un problema los datos duplicados?. ¿Cuando no?



Correlación entre los datos

La correlación mide la relación lineal entre objetos.

$$\text{corr}(\mathbf{x}, \mathbf{y}) = \frac{\text{covariance}(\mathbf{x}, \mathbf{y})}{\text{standard_deviation}(\mathbf{x}) * \text{standard_deviation}(\mathbf{y})} = \frac{s_{xy}}{s_x s_y}, \quad (2.11)$$

where we are using the following standard statistical notation and definitions

$$\text{covariance}(\mathbf{x}, \mathbf{y}) = s_{xy} = \frac{1}{n-1} \sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y}) \quad (2.12)$$

Ojo. El análisis de Pearson asume que:

- Existe una relación lineal entre las dos variables.
- Las observaciones deben ser independientes entre sí.
- La homocedasticidad de cada variable.
- Ausencia de Valores Atípicos Influyentes.
- las violaciones graves de la normalidad pueden afectar la validez de los resultados


$$\text{standard_deviation}(\mathbf{x}) = s_x = \sqrt{\frac{1}{n-1} \sum_{k=1}^n (x_k - \bar{x})^2}$$

$$\text{standard_deviation}(\mathbf{y}) = s_y = \sqrt{\frac{1}{n-1} \sum_{k=1}^n (y_k - \bar{y})^2}$$

$$\bar{x} = \frac{1}{n} \sum_{k=1}^n x_k \text{ is the mean of } \mathbf{x}$$

$$\bar{y} = \frac{1}{n} \sum_{k=1}^n y_k \text{ is the mean of } \mathbf{y}$$

Evaluación visual de la correlación



Gráficos de dispersión que muestran la similitud de -1 a 1 .

Otros tipos de estimadores de correlaciones son

- Correlación de Spearman (ρ):
datos son ordinales
- Correlación de Kendall (τ):
datos no normales

LABORATORIO 6

**Duración aprox:
20 Minutos**

Ejercicio:

1. Use el archivo,
<https://raw.githubusercontent.com/plotly/datasets/master/diabetes.csv>
2. Utilice **Weka** y realice un análisis de los datos del archivo.
3. Use la IA y programe en Python un EDA (Análisis Exploratorio de Datos) y **analice los principales indicadores del modelo.**

Solución:

https://colab.research.google.com/drive/1BOiwdd3xk15jkGqd1_qje66JhKgDzet1?usp=sharing



UNIVERSIDAD
SAN SEBASTIAN
VOCACIÓN POR LA EXCELENCIA




Procesamiento de la información

Agregación

Combinar dos o más atributos (u objetos) en un solo atributo (u objeto)

Propósito

- Reducción de datos
 - Reducir el número de atributos u objetos.
- Cambio de escala
 - Ciudades agregadas en regiones, estados, países, etc.
 - Días agregados en semanas, meses o años
- Más datos "estables"
 - Los datos agregados tienden a tener menos variabilidad



Muestreo

El muestreo es la principal técnica empleada para la reducción de datos.

Muestra es utilizada:

- Investigación preliminar de los datos

- Análisis final de los datos.


El muestreo se utiliza normalmente en ciencia de datos porque procesar todo el conjunto de datos de interés es:

- Demasiado costoso


- Requiere mucho tiempo

Muestreo


Ejemplo



8000 points



2000 Points



500 Points

Muestreo

El principio clave para un muestreo efectivo es el siguiente:

- El uso de una muestra funcionará casi tan bien como el conjunto completo de datos, si la muestra es representativa.
- Una muestra es representativa si tiene aproximadamente las mismas propiedades (de interés) que el conjunto original de datos.

Considerar


1. Definir la población objetivo.
2. Utilizar un muestreo probabilístico:
Muestreo aleatorio simple, Muestreo estratificado, Muestreo por conglomerados, Muestreo sistemático
3. Determinar el tamaño de la muestra.
4. Evitar el sesgo de muestreo: Aleatorio e imparcial.
5. Verificar la representatividad.
6. Documentar cuidadosamente el proceso de muestreo.

Excesiva dimensionalidad

Se refiere al número de atributos, características o variables en un conjunto de datos

Cuando aumenta la dimensionalidad, los datos se vuelven cada vez más escasos en el espacio que ocupa.

Las definiciones de densidad y distancia entre puntos, que son fundamentales para la agrupación y la detección de valores atípicos, pierden sentido.



Reducción de dimensionalidad

Propósito:

- Evitar la excesiva dimensionalidad.
- Reducir la cantidad de tiempo y memoria requerida por los algoritmos de minería de datos
- Permitir que los datos se visualicen más fácilmente
- Puede ayudar a eliminar características irrelevantes o reducir el ruido.

Técnicas:



Reducción de dimensiones

- Análisis de componentes principales (PCA)
- Selección de dimensiones (Feature selection)
- Varias técnicas

Reducción de dimensionalidad

PCA


El objetivo es encontrar una proyección que capture la mayor cantidad de variación en los datos



Reducción de dimensionalidad

PCA


Se construye un pequeño número de nuevas variables (componentes) en las cuales se concentre la mayor cantidad posible de información



Reducción de dimensionalidad

PCA-Ejemplo

- Un análisis consideró las calificaciones escolares de $n = 1500$ estudiantes en $m =$ materias (lengua, matemáticas, física, inglés, filosofía, historia, química, gimnasia).
- Los dos primeros componentes principales explicaban juntos el 82,1% de la varianza. El primero de ellos parecía fuertemente correlacionado con las materias de humanidades (lengua, inglés, filosofía, historia) mientras que el segundo aparecía relacionado con las materias de ciencias (matemáticas, física, química).
- Así parece que existe un conjunto de habilidades cognitivas relacionadas con las humanidades y un segundo relacionado con las ciencias, estos dos conjuntos de habilidades son estadísticamente independientes por lo que un alumno puede puntuar alto en sólo uno de ellos, en los dos o en ninguno.



Reducción de Dimensionalidad

Feature selection

- Selección de características basada en correlación.
Weka CorrelationAttributeEval technique: Correlación (Pearson's) de variables con la clase de salida.
Seleccionar cercanas a 1 o -1.
- Selección de características basada en el aprendizaje.
Utilizar un algoritmo de aprendizaje genérico y evaluar el rendimiento del algoritmo en un conjunto de datos con diferentes subconjuntos de atributos seleccionados.
Se parte tomando todas las variables y se elimina de a una y se elige el mejor conjunto, luego se repite el proceso con ese conjunto

Otras técnicas, seleccionan las variables en base a las consideradas en un árbol de decisión o también métodos regresión LASSO y RIDGE, ELASTIC NET (Hacen 0 los coeficientes de las variables menos importantes).

Reducción de dimensionalidad

Feature selection

Selección de características basada en la ganancia de información

Weka InfoGainAttributeEval Attribute Evaluator.

$\text{InfoGain}(\text{Class}, \text{Attribute}) = H(\text{Class}) - H(\text{Class} \mid \text{Attribute})$.

Ejemplo:

temperature	wind	class
high	low	play
low	low	play
high	low	play
low	high	cancelled
low	low	play
high	high	canceled
high	low	play

$H(X) = -\sum_{\text{clase}} (P_{\text{clase}} * \log_2(P_{\text{clase}}))$, P es probabilidad

$H(\text{Class}) = -(5/7 * \log_2(5/7) + 2/7 * \log_2(2/7)) = 0,863$.

$\text{InfoGain}(\text{Class}, \text{Temperature}) = H(\text{Class}) - H(\text{Class} \mid \text{Temperature})$.

$H(\text{Class} \mid \text{Temperature}(\text{High})) = -(3/4 \log(3/4) + 1/4 \log(1/4)) = 0,811$

$H(\text{Class} \mid \text{Temperature}(\text{Low})) = -(1/3 \log(1/3) + 2/3 \log(2/3)) = 0,918$

$H(\text{Class} \mid \text{Temperature}) = 4/7 * H(\text{Class} \mid \text{Temperature}(\text{Low})) + 3/7 * H(\text{Class} \mid \text{Temperature}(\text{High}))$

$\text{InfoGain}(\text{Class}, \text{Temperature}) = 0,06$

Repitiendo el ejercicio para **$\text{InfoGain}(\text{Class}, \text{wind}) = 0,2$**

Observando los datos se observa también la mayor entropía de la Variable WIND con respecto a la clase.

Reducción de dimensionalidad


Otra forma de reducir la dimensionalidad de los datos.

- **Colinealidades**, Características redundantes
Se duplica gran parte o toda la información contenida en uno o más atributos
Ejemplo: el precio de compra de un producto y el monto del impuesto a las ventas pagado.
- **ANOVA para variable categóricas**
- **Data Leakage**
 - Target Leakage (Fuga de la Variable Objetivo)
 - Train-Test Contamination (Contaminación del Conjunto de Prueba)
 - Temporal Leakage (Fuga Temporal)

Discretización

La discretización es el proceso de convertir un atributo continuo en un atributo ordinal

- Un número potencialmente infinito de valores se asigna en un pequeño número de categorías
- La discretización se usa comúnmente en la clasificación
- Muchos algoritmos de clasificación funcionan mejor si las variables independientes y dependientes tienen solo unos pocos valores



Discretización – Ejemplo

Edad (0-14 años)

Edad (16-24 años)

Edad (25 - 65 años)



Edad	1	1	...	1	2	2	2	...	2	2	2	3	4	5	...	6
# de Autos	14	23	...	45	16	24	23	...	14	45	45	16	24	23	...	45

Discretización – Ejemplo

Conjunto de datos de la planta del iris.
Puede obtenerse en el repositorio de aprendizaje automático de la UCI


<http://archive.ics.uci.edu/ml/index.php>

- Tres tipos de flores (clases):
 - Setosa
 - Versicolor
 - Virginica
- Cuatro atributos (no de clase)
 - Ancho y largo sépalo
 - Ancho y largo del pétalo



Discretización – Ejemplo

Planta del iris.




Así Petal Length, pasaría de continuo a intervalos $[0, 0.83)$, $[0.83, 1.66)$, $[1.66, 2.5)$... etc

Discretización – Ejemplo

Planta del iris.

¿Cómo podemos decir cuál es la mejor discretización?

- Discretización no supervisada: encontrar cortes en los valores de los datos.
Ejemplo: Longitud del pétalo
- Discretización supervisada: use etiquetas de clase para encontrar breaks. Podría ser el árbol de decisión que nos indique breaks.



```

Glucose < 127.5
| Age < 28.5
| | BMI < 30.9 : 0.01 (104/0.01) [46/0.02]
| | BMI >= 30.9 : 0.17 (76/0.1) [45/0.22]
| Age >= 28.5
| | Insulin < 142.5
| | | Glucose < 99.5 : 0.12 (46/0.08) [20/0.17]
| | | Glucose >= 99.5 : 0.38 (73/0.22) [47/0.26]
| | Insulin >= 142.5 : 0.64 (15/0.2) [13/0.29]
Glucose >= 127.5
| BMI < 29.95 : 0.32 (57/0.22) [19/0.2]
| BMI >= 29.95
| | Glucose < 154.5
| | | BMI < 41.65
| | | | DiabetesPedigreeFunction < 0.44 : 0.37 (32/0.23) [11/0.23]
| | | | DiabetesPedigreeFunction >= 0.44
| | | | | Pregnancies < 2.5 : 0.47 (11/0.25) [4/0.25]
| | | | | Pregnancies >= 2.5
| | | | | | DiabetesPedigreeFunction < 0.66 : 1 (10/0) [5/0]
| | | | | | DiabetesPedigreeFunction >= 0.66 : 0.69 (7/0.2) [6/0.22]
| | | BMI >= 41.65 : 0.82 (14/0.07) [8/0.33]
| | Glucose >= 154.5 : 0.86 (67/0.12) [32/0.13]
    
```

Discretización - Método BIN

- Valores numéricos que pueden ser ordenados de menor a mayor.
- Particionar en grupos con valores cercanos
- Cada grupo es representado por un simple valor (media, la mediana o la moda).
- Cuando el número de bins es pequeño, el límite más cercano puede ser usado para representar el bin

Ejemplo:

$f = \{3, 2, 1, 5, 4, 3, 1, 7, 5, 3\}$

Ordenado: $F = \{1, 1, 2, 3, 3, 3, 4, 5, 5, 7\}$

Particionando en 3 BINs: $\{1, 1, 2, \quad 3, 3, 3, \quad 4, 5, 5, 7\}$

Representación usando la moda: $\{1, 1, 1, \quad 3, 3, 3, \quad 5, 5, 5, 5\}$

Representación usando la media:

$\{1.33, 1.33, 1.33, \quad 3, 3, 3, \quad 5.25, 5.25, 5.25, 5.25\}$

Transformación de atributos

Una transformación de atributo es una función que asigna el conjunto completo de valores de un atributo dado a un nuevo conjunto de valores de reemplazo, de modo que cada valor antiguo pueda identificarse con uno de los nuevos valores.

Normalización

- Se refiere a varias técnicas para ajustar las diferencias entre atributos en términos de frecuencia de ocurrencia, media, varianza, rango.
- Eliminar señales comunes no deseadas, por ejemplo, estacionalidad

Normalización

Las formas más comunes de normalización

- Tenemos la normalización min/max, mediante la expresión

$$v' = \frac{v - \min_A}{\max_A - \min_A} (\text{newmax}_A - \text{newmin}_A) + \text{newmin}_A.$$

- Normalización de media cero (o z normalisation)

$$v' = \frac{v - \bar{A}}{\sigma_A},$$

Ojo, la variable normalizada queda con Media=0 y $\sigma = 1$

en donde $\bar{A}$ y σ_A son la media y desviación estándar, respectivamente.

- Normalización mediante escalado decimal
 - ▶ Se mueve el punto decimal en los valores del atributo
 - ▶ Las posiciones dependen del máximo en valor absoluto tal que

$$v' = \frac{v}{10^j},$$

en donde j es el entero más pequeño tal que $\text{Max}(|v'|) < 1$

LABORATORIO 7

**Duración aprox:
20 Minutos**

Ejercicio:

1. Continúe con el archivo de diabetes
2. Utilice **Weka** y realice un PCA (Reducción de Componentes Principales).
3. Utilice **Weka** y realice una discretización.
4. Utilice **Weka** y realice una normalización.
5. Programe en Python un PCA (sin la columna class), una discretización y una normalización media 0 con los datos.

Solución:

<https://colab.research.google.com/drive/1PtSLudFBRiK2QwC94d3KjETMP7j6HE6r?usp=sharing>

Evaluación 60%

Tarea: Aplicación de método de ciencia de datos

Objetivo: Aplicar las técnicas vistas en el curso para extraer información/conocimiento.

Actividades:

1. Trabaje en grupos de dos o de manera personal.
2. Use IA con Python o trabaje con Weka o Knime.
3. Datos: Continúe con los datos seleccionados en el trabajo para la casa.
4. Utilice las fases del método CRISP-DM e indique en cada una, 3 preguntas de gestión asociadas al negocio.
5. Cargue los datos, realice EDA y visualizaciones e indique conclusiones que impacten en los modelos.
6. Justifique y realice transformaciones a los datos que impacten en los modelos, para mejorar las métricas.
7. Profundice en la parametrización de los modelos de “Clasificación”, mejorando las métricas.
8. Resumir en una ppt. de máximo 10 páginas el trabajo realizado y los hallazgos, para presentarlo en la próxima clase y obtener su evaluación.
9. Fecha de entrega el próximo Jueves en blackboard.

Evaluación 60%

Rúbrica

Criterio	100 - Excelente	75 - Satisfactorio	50 - Básico	25 - Insatisfactorio	0 - No entrega
Compleitud de tarea para la casa	Usa agrupamiento, justificando el número de cluster e interpretando cada grupo. Usa clasificación determinando métricas mas adecuadas al negocio. Aplica Apriori y explica 6 reglas	Usa agrupamiento, justificando el número de cluster e interpretando cada grupo. Usa clasificación determinando métricas mas adecuadas al negocio. Aplica Apriori y explica 6 reglas. Presenta errores menores.	Usa algoritmos con análisis básicos y/o incompleto	Usa algoritmos sin analisis básicos	No entrega
Comprensión del Modelo y metodología	Demuestra una comprensión profunda de los conceptos del modelo, incluyendo los algoritmos utilizados y las métricas de evaluación. Usa adecuadamente CRIPS_DM	Muestra una comprensión básica de los conceptos. Usa adecuadamente CRIPS_DM	Muestra una comprensión básica de los conceptos, y puede haber algunas imprecisiones o falta de claridad. Usa limitadamente CRIPS_DM	No demuestra una comprensión adecuada de los conceptos clave. No usa CRIPS_DM	No entrega
Análisis y Transformación de Datos	Analiza y transforma los datos para mejorar los indicadores del modelo.	Analiza y aplica transformaciones útiles para mejorar los resultados.	Realiza Análisis de datos y transformaciones de los datos poco útiles.	Realiza Análisis de datos y transformaciones de los datos poco útiles.	No entrega
Presentación de Resultados	Los resultados se presentan de manera clara, concisa y visualmente atractiva, utilizando gráficos y tablas apropiados.	Los resultados se presentan de manera comprensible, pero la presentación podría mejorarse en términos de claridad o atractivo visual.	Los resultados se presentan de manera comprensible, pero la presentación podría mejorarse en términos de claridad o atractivo visual.	La presentación es confusa, desorganizada o carece de claridad.	No entrega
Interpretación y Conclusiones	Proporciona una interpretación perspicaz y bien fundamentada de los resultados, identificando patrones significativos y extrayendo conclusiones.	Ofrece una interpretación razonable de los resultados, pero puede carecer de profundidad o justificación.	NO entrega una interpretación razonable de los resultados.	La interpretación es superficial, incorrecta o carece de justificación.	No entrega



UNIVERSIDAD
SAN SEBASTIAN
VOCACIÓN POR LA EXCELENCIA



Muchas gracias



UNIVERSIDAD
SAN SEBASTIAN
VOCACIÓN POR LA EXCELENCIA



Santiago

Concepción

Valdivia

Puerto Montt

5 AÑOS
ACREDITACIÓN INSTITUCIONAL
Gestión Institucional
Docencia de Pregrado
 Vinculación con el Medio
ACREDITADA
NIVEL AVANZADO
DESDE OCTUBRE 2021 HASTA OCTUBRE 2026



ACREDITACIÓN INTERNACIONAL
6 años
AQAS

AGENTUR FÜR
QUALITÄTSSICHERUNG DURCH
AKKREDITIERUNG VON
STUDIENGÄNGEN E.V.

www.uss.cl