

Datos reales.

1. Bank Marketing

El dataset Bank Marketing contiene datos de campañas de marketing telefónico de un banco portugués, con información del cliente (edad, profesión, educación, situación financiera), detalles de la campaña (número de contactos, tipo, mes, duración) y una etiqueta binaria que indica si el cliente contrató o no un depósito a plazo. Es un problema de clasificación con desbalance y muchas variables categóricas, ideal para probar modelos de marketing y técnicas de preprocesamiento.

Publicación en UCI: Moro, S., Laureano, R., & Cortez, P. (2014). "Using Data Mining for Bank Direct Marketing: An Application of the CRISP-DM Methodology". Expert Systems with Applications.

<https://archive.ics.uci.edu/dataset/222/bank+marketing>

2. Wine Quality

Wine Quality incluye dos conjuntos (vino tinto y blanco "Vinho Verde" portugués) con 11 variables fisicoquímicas (acidez, pH, alcohol, azúcar residual, etc.) y una calidad sensorial evaluada por enólogos en una escala de 0 a 10. Puede tratarse como clasificación ordinal (p. ej. baja, media, alta calidad) o binaria (vino ≥ 7 vs. < 7), con clases desbalanceadas y relación no lineal entre atributos y calidad. Publicación en UCI: Cortez, P. et al. (2009). "Modeling wine preferences by data mining from physicochemical properties". Decision Support Systems.

<https://archive.ics.uci.edu/dataset/186/wine+quality>

3. Occupancy Detection

Occupancy Detection recoge mediciones ambientales dentro de una sala (temperatura, humedad, luz, CO₂, humedad relativa) junto con la etiqueta de ocupación (1 = ocupada, 0 = vacía) a intervalos de un minuto. El problema es predecir si la sala está ocupada usando solo sensores ambientales, lo que lo hace interesante para IoT y edificios inteligentes; tiene miles de observaciones y tres particiones (train/test1/test2).

Publicación citada: Candanedo, L. M., & Feldheim, V. (2016). "Accurate occupancy detection of an office room from light, temperature, humidity and CO₂ measurements". Energy and Buildings.

<https://archive.ics.uci.edu/dataset/357/occupancy+detection>

4. AI4I 2020 Predictive Maintenance Dataset

El AI4I 2020 contiene datos sintéticos realistas de una planta industrial, con variables de proceso (velocidad de rotación, torque, temperatura, tipo de producto) y etiquetas sobre el estado de la máquina (sin fallo, fallo por desgaste, fallo por sobrecarga, etc.). Permite atacar tanto clasificación binaria (fallo/no fallo) como multiclase, con un tamaño de unos 10.000 registros y mezcla de variables numéricas y categóricas.

Publicación asociada en UCI: H. A. B. et al. (2020). "AI4I 2020: A Dataset for Predictive Maintenance Modeling". Data in Brief (referido en la descripción del dataset).

<https://archive.ics.uci.edu/dataset/601/ai4i+2020+predictive+maintenance+dataset>

5. Abalone

Abalone contiene medidas físicas de abalones (longitud, diámetro, altura, peso total, pesos de órganos, etc.) y la variable "rings", que se usa típicamente para estimar la edad; puede discretizarse para generar clases de edad (joven, adulto, viejo). Aunque originalmente es de regresión, UCI lo documenta también como caso de clasificación al agrupar la edad, siendo útil para practicar discretización y clasificación con datos biológicos.

Publicación citada: Nash, W. J. et al. (1994). "The Population Biology of Abalone in Tasmania. I. Blacklip Abalone (*Haliotis rubra*) from the North Coast", listado en la descripción del dataset.

<https://archive.ics.uci.edu/dataset/1/abalone>

6. Student Performance

El dataset Student Performance recoge información de 649 estudiantes de enseñanza secundaria de dos colegios portugueses, con 30 variables demográficas, familiares, sociales y académicas, además de las notas de tres periodos en Matemáticas y Lengua Portuguesa. Se puede abordar como problema de clasificación (por ejemplo, aprobar/suspender o niveles de rendimiento) o de regresión sobre la nota final G3, teniendo en cuenta que esta se correlaciona fuertemente con G1 y G2, lo que plantea decisiones interesantes de modelado al excluir o incluir estas notas parciales. Resulta muy adecuado para estudios sobre factores asociados al rendimiento, fairness educativa y comparación de modelos interpretable vs. "caja negra" en un contexto social realista.

Publicación introductoria indicada en UCI: Cortez, P., & Silva, A. M. G. (2008). "Using Data Mining to Predict Secondary School Student Performance", presentada en el 5th Annual Future Business Technology Conference, que modela estos datos en tareas de clasificación binaria / de cinco niveles y regresión.

<https://repositorium.sdum.uminho.pt/bitstream/1822/8024/1/student.pdf>

<https://archive.ics.uci.edu/dataset/320/student+performance>

7. Drug Consumption (Quantified)

El dataset Drug Consumption (Quantified) contiene 1.885 registros de personas para las que se midieron 12 atributos: edad, género, nivel educativo, país, etnia y una batería de rasgos de personalidad (cinco grandes factores NEO-FFI-R, impulsividad BIS-11 y búsqueda de sensaciones ImpSS) cuantificados en escala continua. A cada individuo se le preguntó por su consumo de 18 drogas legales e ilegales (alcohol, cannabis, cocaína, nicotina, etc.), registrando la frecuencia en siete categorías ordenadas desde “nunca usado” hasta “usado en el último día”; esto genera 18 problemas de clasificación separados y potencialmente binarizables (usuario vs. no usuario). Es un caso muy rico para estudiar cómo la personalidad y variables sociodemográficas se relacionan con el riesgo de consumo de distintas sustancias, evaluar distintas estrategias de umbralización de clases y comparar modelos en escenarios multiclase desbalanceados.

Publicación introductoria indicada en UCI: Fehrman, E., Muhammad, A. K., Mirkes, E. M., Egan, V., & Gorban, A. N. (2015). “The Five Factor Model of personality and evaluation of drug consumption risk”, donde se abordan tareas de clasificación binaria para cada droga logrando sensibilidades y especificidades superiores al 75% en la mayoría de los casos.

<https://arxiv.org/pdf/1506.06297>

<https://archive.ics.uci.edu/dataset/373/drug+consumption+quantified>

8. Mushroom

El dataset Mushroom contiene 8.124 registros de hongos con 22 atributos categóricos que describen sus características morfológicas: forma, superficie y color del sombrero, presencia de moretones, olor, tipo y color de láminas, forma y color del tallo, tipo de velo, anillo, color de la esporada, población y hábitat, entre otros. Cada muestra pertenece a una de 23 especies de la familia Agaricus-Lepiota y está etiquetada como comestible o venenosa, fusionando en esta última categoría los casos de “edibilidad desconocida” que la guía de campo no recomienda consumir.

Entre las publicaciones que utilizan este dataset, la ficha de UCI lista, por ejemplo, a Pinky, N., Islam, S., & Alice, R. (2019). “A Comparative Study of Decision Tree Algorithms for Mushroom Classification”, publicado en el *International Journal of Image, Graphics and Signal Processing*, donde se comparan distintos algoritmos de clasificación aplicados a estos datos.

<https://archive.ics.uci.edu/dataset/73/mushroom>

9. Human Activity Recognition Using Smartphones

El dataset Human Activity Recognition Using Smartphones contiene 10.299 registros obtenidos a partir de 30 voluntarios que realizaron seis actividades de la vida diaria (caminar, subir/bajar escaleras, sentarse, estar de pie y acostarse) mientras llevaban un smartphone Samsung Galaxy S II en la cintura. Los sensores de acelerómetro y giróscopo registraron aceleraciones y velocidades angulares tri-axiales a 50 Hz, y esas señales se segmentaron en ventanas deslizantes de 2,56 segundos con 50% de solapamiento, a partir de las cuales se calcularon 561 características en dominio de tiempo y frecuencia. El conjunto está ya particionado en entrenamiento y prueba, e incluye para cada ventana el identificador del sujeto y la etiqueta de actividad, lo que lo hace ideal para problemas de clasificación multiclase, evaluación de modelos de reconocimiento de actividades y estudios de generalización entre sujetos.

El artículo introductorio indicado en UCI es: Anguita, D., Ghio, A., Oneto, L., Parra, X., & Reyes-Ortiz, J. L. (2013). "A Public Domain Dataset for Human Activity Recognition Using Smartphones", presentado en el *European Symposium on Artificial Neural Networks (ESANN)*, donde se describen los detalles experimentales y se reporta el desempeño de modelos basados en redes neuronales y máquinas de soporte vectorial sobre este dataset.

<https://archive.ics.uci.edu/dataset/240/human+activity+recognition+using+smartphones>

10. Estimation of Obesity Levels Based On Eating Habits and Physical Condition

El dataset Estimation of Obesity Levels Based On Eating Habits and Physical Condition contiene 2.111 registros de personas de México, Perú y Colombia, con 17 atributos que describen sexo, edad, talla, peso, antecedentes familiares de sobrepeso, hábitos alimentarios (frecuencia de comida hipercalórica, consumo de verduras, número de comidas, snacks entre comidas), tabaquismo, actividad física y uso de transporte, entre otros. La variable objetivo NObesity clasifica a cada individuo en siete niveles: Insufficient Weight, Normal Weight, Overweight Level I y II, y Obesity Type I, II y III, lo que configura un problema de clasificación multiclase que también puede abordarse como regresión ordinal o clustering de perfiles de riesgo.

El artículo introductorio señalado en UCI es: Mendoza Palechor, F., & De la Hoz Manotas, A. (2019). "Dataset for estimation of obesity levels based on eating habits and physical condition in individuals from Colombia, Peru and Mexico", publicado en *Data in Brief*.

<https://archive.ics.uci.edu/dataset/544/estimation+of+obesity+levels+based+on+eating+habits+and+physical+condition>

11. Clickstream Data for Online Shopping

El dataset Clickstream Data for Online Shopping contiene 165.474 registros de clics en una tienda online de ropa para mujeres embarazadas, recopilados durante cinco meses del año

2008. Cada fila representa un clic dentro de una sesión e incluye fecha (año, mes, día), orden del clic en la sesión, país de origen de la IP, identificador de sesión, categoría principal de producto, modelo específico (217 productos), color, ubicación de la foto en la pantalla y precio del producto, entre otras variables. Es un conjunto secuencial de tamaño medio–alto que permite estudiar trayectorias de navegación y tareas de clasificación.

El artículo introductorio indicado en UCI es: Łapczyński, M., & Białowas, S. (2013). “Analiza zachowań klientów sklepu internetowego z wykorzystaniem danych clickstream” (*Studia Ekonomiczne*), donde se describen los datos y se exploran distintos patrones de navegación y compra a partir de este clickstream.

<https://archive.ics.uci.edu/dataset/553/clickstream+data+for+online+shopping>

12.Nursery

El dataset Nursery contiene 12.960 solicitudes de admisión a jardines infantiles de Ljubljana (Eslovenia), derivadas de un modelo jerárquico de decisión usado en los años 80 para priorizar el ingreso cuando había exceso de demanda. Cada registro está descrito por ocho atributos categóricos que resumen ocupación de los padres, situación previa del niño (si ya tiene jardín), estructura y tamaño de la familia, condiciones de vivienda, situación financiera, condiciones sociales y de salud de la familia. La variable objetivo “class” clasifica cada solicitud en categorías como recommended, priority, not_recom, entre otras.

El trabajo introductorio señalado en UCI es: Olave, M., Rajkovic, V., & Bohanec, M. (1989). “An expert system for admission to nursery schools”, publicado en *Expert Systems in Public Administration*, donde se presenta el modelo DEX de decisión jerárquica que dio origen a este conjunto de datos.

<https://archive.ics.uci.edu/dataset/76/nursery>
